



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

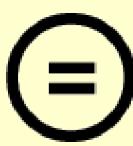
다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원 저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리와 책임은 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)



공학석사 학위논문

대규모 언어 모델(LLM)과 양상블 머신러닝 모델을
융합한 한국인 감정분석 모델 설계

정보통신공학과

김 현 지

지도교수 오유수

2024년 8월

대구대학교 대학원

대규모 언어 모델(LLM)과 앙상블 머신러닝 모델을 융합한 한국인 감정분석 모델 설계

이 논문을 공학석사 학위논문으로 제출함.

정 보 통 신 공 학 과

김 현 지

지 도 교 수 오 유 수

김현지의 공학석사 학위논문을 인준함.

2024년 8월

심사위원장 _____(인)

심사위원 _____(인)

심사위원 _____(인)

대구대학교 대학원

목 차

I. 서론	1
II. 관련 연구	5
1. BERT	5
2. Ensemble Machine Learning	7
III. 대규모 언어 모델(LLM)과 양상블 머신러닝 모델을 융합한 한국인 감정분석 모델 설계	9
IV. 응용시스템 개발	11
1. 단어의 감정적 요소를 포함하는 대규모 언어 모델(LLM)과 양상블 머신러닝 모델을 융합한 한국인 감정분석 시스템	11
1) 단어의 감정적 요소를 포함하는 한국인 감정분석 시스템	11
2) 실험 및 평가	14
2. 대규모 언어 모델(LLM)과 양상블 머신러닝 모델을 융합한 한국 자폐 아동들의 감정분석 시스템	16
1) 한국 자폐 아동들의 감정분석 시스템	16
2) 실험 및 평가	20
3. 대규모 언어 모델(LLM)과 양상블 머신러닝 모델을 융합한 한국인 감정 분석 시스템을 이용한 선택적 Llama2 모델 감정분석 챗봇 시스템	26
1) 한국인 감정분석 시스템을 이용한 챗봇 시스템	26
2) 실험 및 평가	30

V. 결론	35
참고문헌	36
영문초록	39

표 목 차

표 1. 감정 사전학습에 사용된 데이터	12
표 2. 감정 사전에서 감정 데이터를 Fasttext로 학습한 결과	13
표 3. 제안된 시스템을 통한 감정분석 결과	14
표 4. Measurement of the accuracy of each system's chatbot-type response	25
표 5. Experience Result (Excerpts of some sentences from the test data)	25
표 6. 사용하는 데이터 구성	28
표 7. 감정분석 모듈 결과	28
표 8. 감정 카테고리 선택기 알고리즘 의사 코드	29
표 9. 제안한 시스템의 챗봇 답변 결과	32
표 10. 챗봇 시스템의 코사인 유사도 값	33
표 11. 챗봇 시스템 간의 BLEU 결괏값	34

그 림 목 차

그림 1. Input Representation – BERT	5
그림 2. BERT 모델 구조	6
그림 3. 양상블 머신러닝 중 Bagging 학습 구조	7
그림 4. 양상블 머신러닝 중 Hard Voting 학습 구조	8
그림 5. 양상블 머신러닝 중 Soft Voting 학습 구조	8
그림 6. 대규모 언어 모델(LLM)과 양상블 머신러닝 모델을 융합한 한국인 감정분석 모델	10
그림 7. 단어의 감정적 요소를 포함하는 KoBERT 모델과 양상블 머신러닝 모델을 결합한 한국인 감정분석 시스템 동작 다이어그램	11
그림 8. 단일 분류 머신러닝 알고리즘의 조합에 따른 정확도	15
그림 9. Random Forest 학습 후 생성한 혼동행렬 그래프	15
그림 10. 딥러닝 감정분석 모듈(DL_Emotioner) Train/Test 정확도 및 Loss 값	16
그림 11. SBERT와 양상블 머신러닝 결합한 자폐 아동들의 감정분석 시스템	17
그림 12. 임곗값에 따른 성능 평가 결과	19
그림 13. 감정분석 모델 정확도 비교 벤치마크	20
그림 14. S-BEL Mixture Model BLEU, Cosine-Similarity Score	22
그림 15. Ensemble Machine (MultinomialNB, RandomForestClassifier, XGBoost) BLEU, Cosine-Similarity Score	22
그림 16. Ensemble Machine (MultinomialNB, RandomForestClassifier) BLEU, Cosine Similarity Score	23
그림 17. Ensemble Machine (MultinomialNB, XGBoost) BLEU, Cosine-Similarity Score	23
그림 18. Ensemble Machine (RandomForestClassifier, XGBoost) BLEU, Cosine Similarity Score	24
그림 19. Cosine Similarity Score와 BLEU 점수 그래프의 상관관계	24

그림 20. 감정분석 챗봇 시스템 성능 향상을 위한 KoBERT 기반 감정 분류기와 선택적 Llama 2 모델 다이어그램	27
그림 21. KoBERT 기반 감정분석 모듈에 대한 정확도 그래프	31
그림 22. 코사인 유사도 결과 그래프	33
그림 23. BLEU 결과 그래프	34

대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 모델 설계

김 현 지

대구대학교 대학원
석사과정 정보통신공학과

지도교수 오 유 수

(초 록)

최근 인공지능 시장의 발전으로 인공지능이 직업을 대체하는 사례들이 증가하고 있다. 반면에 인공지능으로 대체되지 않는 직업들도 존재한다. 인공지능으로 대체되지 않는 직업들은 대부분 보육교사, 심리 상담사와 같이 인간과 감정적으로 교류해야 하는 직업은 대체 가능성성이 크지 않다. 감정은 외부의 상황에 대하여 나타나는 마음이나 느낌으로 정의된다. 이처럼, 상황에 영향을 많이 받는 감정은 단순히 알고리즘을 통해 학습하는 인공지능으로 파악하기 어렵다.

인간의 감정은 언어, 음성 및 표정을 통해 표현될 수 있다. 언어는 상황에 따라 의미를 가진 단어를 구성하여 표현되기 때문에 감정 요소를 포함한다. 그러나 음성 및 표정은 개인의 의지로 감정이 표현되는 방식을 숨기거나 조절할 수 있다. 또한, 한국어는 영어와 달리 상황에 따라 의미가 변화하는 복합어와 동음이의어를 가지고 있다. 따라서 본 논문은 딥러닝을 통해 상황에 따른 언어의 감정을 파악하고 머신러닝을 통해 문장 자체가 가지는 감정을 파악 후 두 모델의 결과를 융합하여 감정을 분석이 가능한 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 모델 설계를 제안한다.

본 논문은 한국인 감정분석 모델을 위해 딥러닝을 이용한 감정분석 모듈(DL_Emotioner), 양상을 머신러닝 알고리즘을 이용한 감정분석 모듈(ML_Emotioner), DL_Emotioner와 ML_Emotioner를 융합하는 Mixture_Emotioner 모듈을 제안한다. DL_Emotioner은 문맥 파악에 높은 성능을 보이는 BERT 알고리즘을 통해 구현한다. ML_Emotioner 단

일 분류 머신러닝 모델에 비해 높은 성능을 보이는 양상을 머신러닝 알고리즘을 이용하여 구현한다. 본 논문은 Mixture_Emotioner를 통해 딥러닝을 이용한 상황에 따른 감정분석뿐만 아니라 문장 자체의 감정분석이 가능한 머신러닝 알고리즘을 융합하여 최종 감정을 도출함으로 인해 한국어의 특성을 고려하면서 정확한 감정분석이 가능하다.

본 논문은 상황에 따른 감정분석과 문장 혹은 단어가 가지고 있는 감정분석을 융합함으로 인해 세밀한 감정분석이 가능하다. 본 논문은 다양한 응용시스템 구현을 통해 제안하는 시스템의 성능을 판단한다.

본 논문에서는 대규모 언어 모델과 양상을 머신러닝 모델을 융합한 한국인 감정분석 모델의 응용으로 감정분석 시스템들을 구현하였다. 본 논문에서는 단어의 감정적 요소를 포함하는 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 시스템, 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국 자폐 아동들의 감정분석 시스템과 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 시스템을 이용한 선택적 Llama2 모델 감정분석 챗봇 시스템을 구현하였다.

I .서론

COVID-19 이후 외부 활동이 줄면서 사람 간의 감정적 교류가 감소함으로 인해 코로나 블루가 증가했다[1]. 또한, 대면 서비스가 어려워지면서 비대면 서비스가 증가하였다. 포스트 코로나 시대로 접어든 현재에도 비대면 서비스는 계속되고 있다[1]. 비대면 서비스가 증가하고 최근 인공지능 시장이 커지고 인공지능의 성능이 향상되면서 인공지능으로 대체하는 직업이 증가하고 있다. Open AI에서 발표한 ChatGPT[2] 같은 경우 예술, 창작뿐만 아니라 단순 서류 작업, ARS 등에 사용되면서 해당 직업들이 인공지능으로 대체되고 있다[3]. 반면에 인공지능으로 대체되지 않는 직업들도 존재한다. 예를 들어, 무인 자동차의 개발로 인해 대중교통을 담당하는 운전기사는 대체될 확률이 높지만, 보육교사, 심리 상담사와 같이 인간과 감정적으로 교류해야 하는 직업은 대체 가능성성이 크지 않다[3]. 이와 같이, 인공지능은 알고리즘을 통한 지능적 학습만 하기 때문에 상황에 따른 감정적 요소를 파악하기 어렵다[3].

감정은 외부의 상황에 대하여 나타나는 마음이나 느낌이다[4]. 인간의 감정은 언어, 음성 및 얼굴 표정을 통해 표현될 수 있다. 언어는 상황에 따라 의미를 가진 단어를 구성하여 표현되기 때문에 감정 요소를 포함한다. 그러나 음성 및 표정은 개인의 의지로 감정이 표현되는 방식을 숨기거나 조절할 수 있다[5]. 한국어는 영어와 달리 상황에 따라 의미가 변화하는 복합어와 동음이의어, 다의어를 가지고 있다. 다의어 중 예를 들면, "하..."와 같은 의성어는 단어 한숨을 표현하고 긍정적인 상황에서는 기쁨을, 부정적인 상황에서는 슬픔이나 좌절감을 표현한다. 이처럼 다의어는 문장의 맥락을 이해함으로써 의미를 파악할 수 있다. 따라서 본 논문에서는 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 모델을 제안한다. 제안한 모델은 대규모 언어 모델인 BERT 이용한 감정분석 모듈(DL_Emotioner)과 양상을 머신러닝 모델을 이용한 모듈(ML_Emotioner)을 제안한다. 제안하는 시스템은 DL_Emotioner와 ML_Emotioner 모듈에서 나온 예측값들을 융합하여 최종 감정을 도출하는 모듈(Mixture_Emotioner)을 제안한다.

본 논문에서는 대규모 언어 모델과 양상을 머신러닝 모델을 융합한 한국인 감정분석 모델의 적용하여 감정분석 응용시스템들을 구현하였다. 본 논문에서는 단어의 감정적 요소를 포함하는 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 시스템, 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국 자폐 아동들의 감정분석 시스템과 대규모 언어 모델(LLM)과 양상을 머신러닝 모

델을 융합한 한국인 감정분석 시스템을 이용한 선택적 Llama2 모델 감정분석 챗봇 시스템을 구현하였다.

단어의 감정적 요소를 포함하는 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 시스템은 한국어 특성을 반영한 감정분석 시스템이다. 제안한 시스템은 대규모 언어 모델인 KoBERT를 사용하였다. 딥러닝 모델 중 BERT 모델은 맥락을 이해할 수 있는 대규모 자연어 처리 알고리즘이다. BERT 모델은 문장 내 단어를 무작위로 마스킹하여 학습한 다음 양방향 학습을 통해 마스킹 된 단어를 예측한다[6]. BERT 모델은 맥락 내에서 단어 간의 관계를 이해할 수 있지만, 단어에 포함된 감정적 요소를 고려하지 못한다. 본 논문에서는 양상을 머신러닝 중 RandomForest 알고리즘을 기반으로 단어의 감정적 요소를 포함하는 한국인 감정분석 시스템 설계를 제안한다. 제안한 시스템은 6가지 감정(기쁨, 슬픔, 분노, 수치심, 상처, 걱정)을 분석한다. 제안하는 시스템은 감정 단어 사전, 감정분석 딥러닝 모듈(DL_Emotioner), 감정분석 머신러닝 모듈(ML_Emotioner), 최종 감정 도출 모듈(Mixture_Emotioner)로 구성되어 있다. 제안하는 시스템은 단어의 감정 요소를 식별하기 위해 감정에 따른 감정 단어 사전을 구축한다. 제안된 감성 단어 사전은 감성 문장을 토큰화하고 전처리를 수행한다. 전처리된 단어에 Fasttext를 적용하여 감성이 포함된 단어 벡터를 생성한다. FastText는 단어의 각 문자 단위인 n-그램에 대한 단어 임베딩을 수행하는 신경망 모델이다[7]. Fasttext는 OOV(Out-Of-Vocabulary)에서 높은 성능을 보여준다[7]. 제안된 시스템은 한국어 데이터로 학습한 KoBERT 모델을 Fine-Tuning 하여 감성 분석 딥러닝 모듈(DL_Emotioner)을 구축한다. 감정분석 머신러닝 모듈(ML_Emotioner)은 양상을 머신러닝 알고리즘을 사용하여 구성된 감정 단어 사전 데이터를 학습한다. 양상을 머신러닝은 여러 분류기를 결합하여 단일 분류 모델을 사용할 때보다 높은 정확도를 도출한다[8]. 감정분석 머신러닝 모듈(ML_Emotioner)은 문장을 구성하는 각 단어의 감정을 분석한다. 제안된 감정분석 머신러닝 모듈(ML_Emotioner)은 각 단어에 대한 감정을 분석하고 분석 결과를 통합하여 결과를 도출한다. 제안된 시스템은 최종 감정 계산 모듈을 통해 도출된 감정 딥러닝 모듈(DL_Emotioner)과 감정 머신러닝 모듈(ML_Emotioner)의 각 감정에 대한 확률값을 가중치로 곱하여 최종 감정을 분석한다. 본 논문에서는 정확도, recall, precision 및 F1-Score를 통해 제안된 감정분석 시스템의 성능을 검증한다[9]. 제안된 시스템은 감정 단어에 대한 학습으로 인해 단일 단어에 대한 감정을 분석한다.

대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국 자폐 아동들의 감정분석 시스템은 대규모 언어 모델과 양상을 머신러닝 융합 모델을 이용하여 자폐 아

동들의 감정을 분석한다. 발달 장애는 사회적 관계, 의사소통, 인지 발달이 지연되거나 비정상적으로 나타난다[10]. 발달 장애 유형 중 자폐아는 언어 및 의사소통 발달이 지연되는 것이 특징이다. 자폐 아동은 단순한 언어와 반복적인 행동을 통해 감정을 표현한다. 따라서 보호자가 자폐 아동의 감정을 파악하기가 어렵다[10]. 본 논문은 단순하고 반복적인 문장에 대한 감정을 분류하기 위해 제안한 대규모 언어 모델과 양상을 머신러닝을 융합을 이용한 한국인 감정분석 모델을 적용한다. 본 논문은 대규모 언어 모델 중 Sentence-BERT 모델을 사용하여 DL_Emotioner를 구성한다. Sentence-BERT(SBERT)는 BERT의 출력에 풀링 연산을 추가하여 문장 임베딩 성능을 향상시키는 모델이다[11]. SBERT는 모든 입력 문장에 대해 벡터를 출력하고 코사인 유사성 계산을 통해 의미가 있는 문장 임베딩을 도출한다[12]. 본 논문에서는 양상을 머신러닝 모델 중 Voting Classifier 양상을 모델을 사용한다. Voting Classifier 양상을 모델은 머신러닝 모델을 2개 이상 배치하여 학습한다. 마지막으로 Voting Classifier는 최종 예측을 도출하기 위해 학습에 사용된 머신러닝 결과에 투표한다[13]. 본 연구에서는 SBERT를 이용한 DL_Emotioner 모듈과 Voting Classifier 양상을 모델을 이용한 ML_Emotioner 모듈을 결합한 S-BEL(Sentence BERT - Ensemble Learning) Mixture 모델을 제안한다. 제안된 S-BEL Mixture 모델은 모든 입력 문장에 대해 고정 벡터를 도출하고 의미 가중치를 부여한다. 본 논문에서는 자폐 아동에 대한 데이터 수집의 어려움으로 인해 비장애인의 감정 대화 데이터를 활용하여 모델을 구축하였다. 제안된 S-BEL Mixture 모델은 비장애인의 감정 분류와 단순 단어들로 이루어진 문장에 대한 감정 분류가 가능하다. 또한, 제안된 S-BEL Mixture 모델은 분석된 감정에 대응하는 적절한 챗봇 형태로 답변을 생성한다.

대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 시스템을 이용한 선택적 Llama2 모델 감정분석 챗봇 시스템은 제안한 감정분석 시스템을 이용하여 감정분석 챗봇 시스템 성능 향상을 위해 제안한다. 제안하는 시스템은 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 감정분석 시스템과 감정 분류기, 선택적 Llama 2 모델로 구성한다. 인간의 대화에는 상황에 따른 감정이 포함되어 있다. 반면 챗봇은 대화의 흐름을 잘 파악하지 못하거나 일관성 있는 답변을 생성하기 어렵다[14]. 언어적 감정 대화들은 상황에 따른 문장에 따라 답변이 달라진다. 예를 들면 “오늘 하루 바빴어”와 같은 문장은 상황에 따라 너무 바빠서 [힘든 감정]일 수도 있고 일이 많이 들어와서 좋은 [기쁜 감정] 일 수도 있다. “오늘 면접에서 떨어졌어”와 같은 문장에서는 상황에 따라 면접에서 떨어져서 [슬픈 감정] 일 수도 있고 면접을 잘하지 못한 [분노의 감정] 일 수도 있다. 이와같이 상황에 따라 같은 문장이어도

다른 감정을 표출할 수 있다. 하지만 기존 챗봇들은 감정과 관련된 문장 데이터 전체를 학습하기 때문에 상황에 따른 감정을 고려하지 않고 챗봇 답변을 도출하는 경우가 존재한다. 제안하는 시스템은 대규모 언어 모델인 DL_Emotioner, ML_Emotioner와 Mixture_Emotioner를 사용하여 감정을 파악한다. DL_Emotioner은 KoBERT 사전학습 모델 파인 투닝을 통해 사용자 문장에 대한 감정을 분석하고 감정별 확률을 도출한다. KoBERT는 SKT Brain에서 개발한 BERT의 한국어 성능을 향상 시킨 모델이다[15]. ML_Emotioner은 앙상블 머신러닝 중 Random Forest 알고리즘을 통해 학습 후 Mixture_Emotioner를 통해 최종 감정을 도출한다. 제안하는 시스템은 상황별 감정 분석을 위해 감정 카테고리의 경우의 수를 구하여 경우의 수에 따라 챗봇 모델을 구축한다. 감정 경우의 수에 따른 챗봇 모델은 Llama 2를 파인 투닝하여 학습한다. Llama 2는 메타에서 공개한 대규모 AI 언어 모델이다[16]. 본 논문은 감정분석 결과를 바탕으로 설계한 Llama 2 챗봇 모델을 선택하고 선택한 챗봇 모델을 통해 챗봇 답변을 도출한다. 본 논문은 기존 감정 챗봇과 제안된 시스템의 정확도 실험 및 평가를 통해 제안한 시스템의 성능을 확인하였다. 그 결과, 제안한 시스템은 상황에 따른 감정분석과 감정분석 결과에 따른 챗봇형 답변이 기존 감정 챗봇보다 높은 정확도를 도출하는 것을 확인하였다.

본 논문은 총 5장으로 구성된다. 2장에서는 본 논문과 관련된 관련 연구들을 소개한다. 3장에서는 대규모 언어 모델과 앙상블 머신러닝 융합한 한국인 감정분석 시스템 설계에 관해 서술한다. 4장은 제안한 감정분석 시스템을 응용한 연구에 관해 서술한다. 마지막 5장은 본 연구의 결론과 향후 연구 방향을 제시한다.

II. 관련 연구

1. BERT

BERT(Bidirectional Encoder Representations from Transformers, BERT)는 2019년 구글에서 발표한 트랜스포머의 양방향 인코더 언어 모델이다[6]. BERT는 트랜스포머의 Encoder를 이용하여 구현되었으며 사전학습된 대용량의 레이블링이 되지 않는 테이터를 이용하여 학습한다[6]. BERT는 Token Embedding, Segment Embedding, Position Embedding 3가지 임베딩 값으로 합을 구하여 입력으로 사용한다. 그림 1은 BERT Input 데이터를 표현하는 임베딩 구조이다. Token Embeddings는 WordPiece 임베딩 방식을 사용한다. WordPiece는 BPE(Byte Pair Encoding)을 기반으로 한 임베딩으로 모든 단어를 나누고 likelihood를 가장 높이는 쌍을 병합하는 임베딩이다. 따라서 Token Embedding은 각 문자 단위로 임베딩하고 자주 등장하는 가장 긴 길이의 문자열을 하나의 단위로 만든다. Segment Embedding은 토큰화시킨 단어들을 다시 하나의 문장으로 만든다. 두 개의 문장을 [SEP]라는 구분자를 넣어 구분하고 첫 번째 [SEP] 토큰까지는 0, 그 이후 [SEP] 토큰까지는 1로 Mask를 만들어 각 문장을 구분한다[6]. 따라서 Segment Embedding은 두 문장을 하나의 Segment로 지정하여 입력한다. Position Embedding은 토큰의 순서를 인코딩한다. BERT는 트랜스포머의 Self-Attention을 이용하기 때문에 입력의 위치를 고려하지 못한다. 따라서 BERT는 학습을 통해서 얻는 Position Encoding을 통해 입력 토큰의 위치 정보를 제공한다[6].

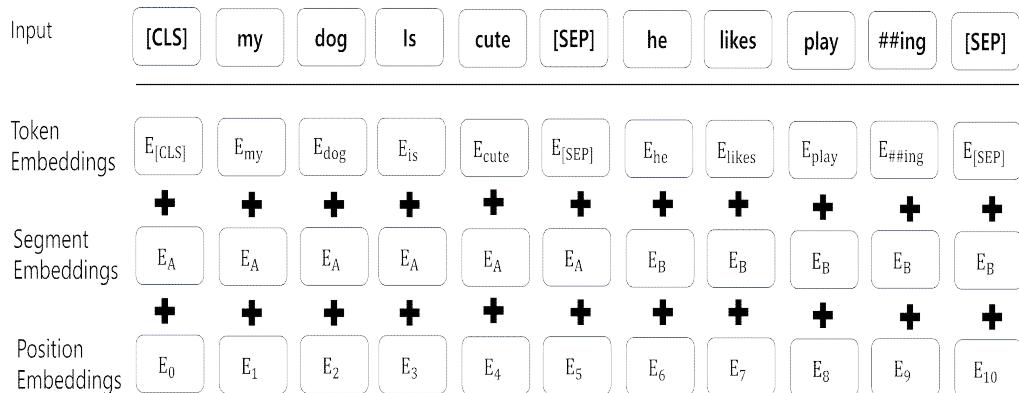


그림 1. Input Representation - BERT

BERT 모델은 문장 표현을 학습하기 위해서 비지도 학습 방법을 사용한다. BERT는 랜덤하게 입력된 토큰 일부를 마스킹한 후 마스킹한 토큰의 정답을 예측하는 것을 목표로 학습한다[6]. 또한, BERT Model은 Next Sentence Prediction(NSP)을 이용하여 학습을 진행하여 문맥 파악이 가능하다[6]. 그림 2는 두 문장 관계에 대해 분류하는 BERT 모델의 구조이다. 입력으로 2개의 문장을 서로 다른 문장임을 알려주는 [SEP] 토큰 기준으로 입력을 넣는다. 또한, [CLS] 토큰 위에 C(Classification layer)를 추가함으로써 최종 [CLS] 토큰을 통과하여 분류한다[6].

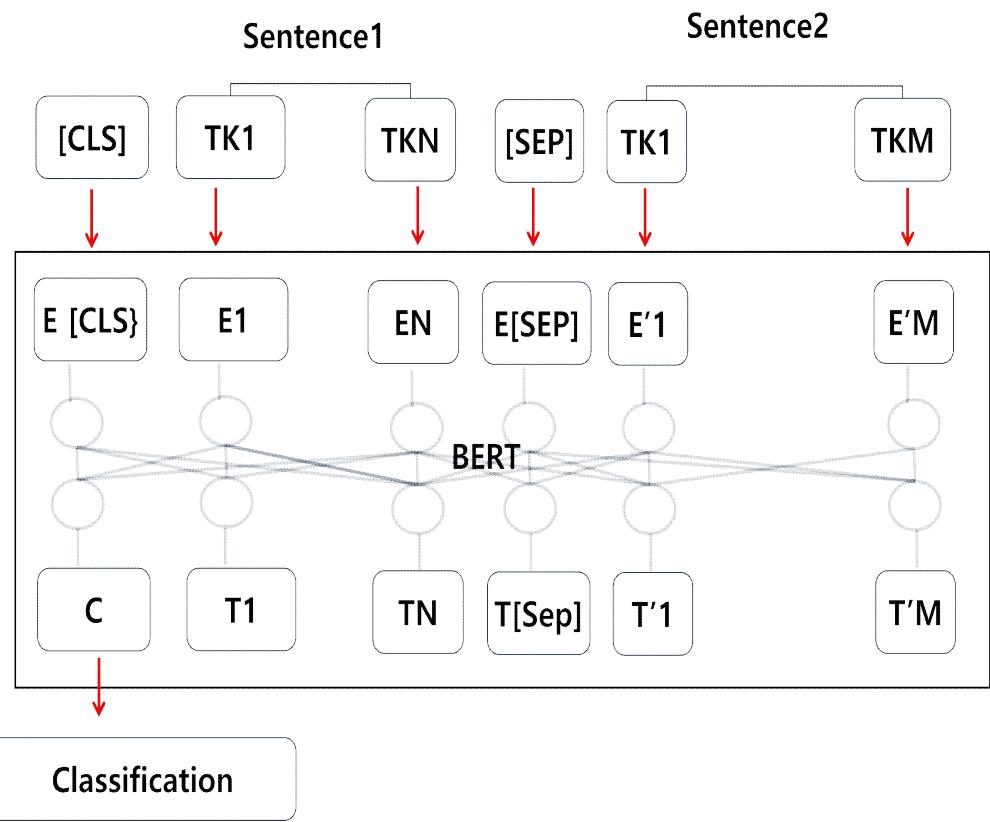


그림 2. BERT 모델 구조

2. Ensemble Machine Learning

양상을 머신러닝은 여러 개의 단일 분류 모델을 조합하여 향상된 성능을 내는 모델로 만드는 방법이다. 양상을 기법은 약한 분류 모델을 결합하여 강한 분류 모델을 만든다. 따라서 양상을 기법은 대체로 단일 분류 모델보다 향상된 예측 성능을 보인다[17]. 양상을 머신러닝 기법으로는 배깅(Bagging) 기법, Voting 기법이 있다. 배깅은 Bootstrap Aggregation의 약자로 샘플을 여러 번 뽑아 각 모델을 학습시켜 결과물을 집계하는 방법이다. 그림 3은 배깅 학습 방법을 나타낸다. 배깅 기법은 학습 데이터가 충분하지 않더라도 높은 성능을 보여준다. 따라서 배깅은 과적합이나 과소 적합에 높은 성능을 보인다[17].

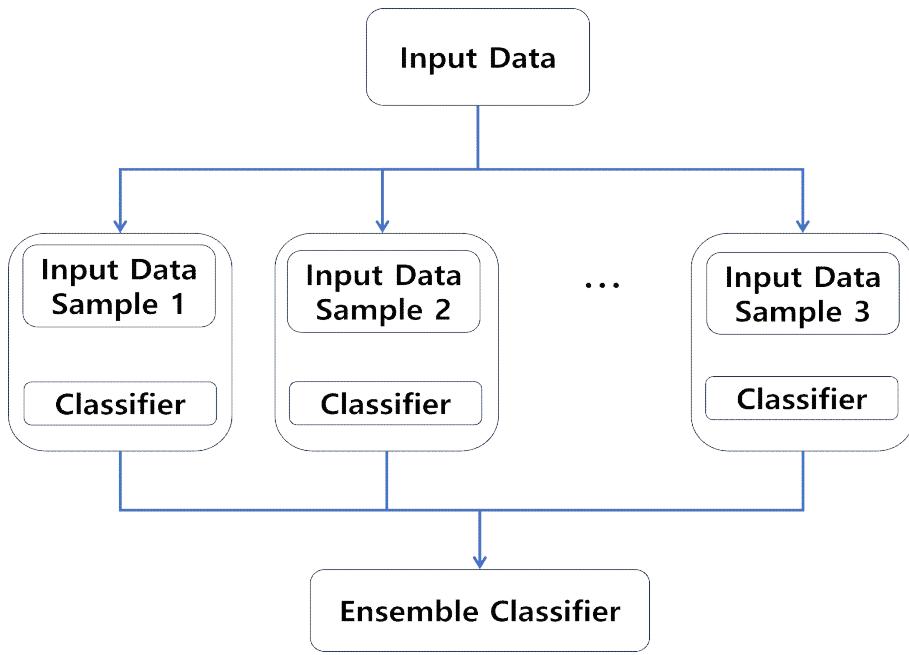


그림 3. 양상을 머신러닝 중 Bagging 학습 구조

Voting은 Hard Voting과 Soft Voting이 있다. Hard Voting은 다수의 분류기의 예측 결괏값 중 가장 많이 도출된 결괏값을 최종 결과로 결정한다. Soft Voting은 다수의 분류기 모델의 예측 결괏값의 확률을 평균하여 최종 결과로 결정한다[17]. 그림 4는 Hard Voting 학습 구조이다. 그림 5는 Soft Voting의 학습 구조이다.

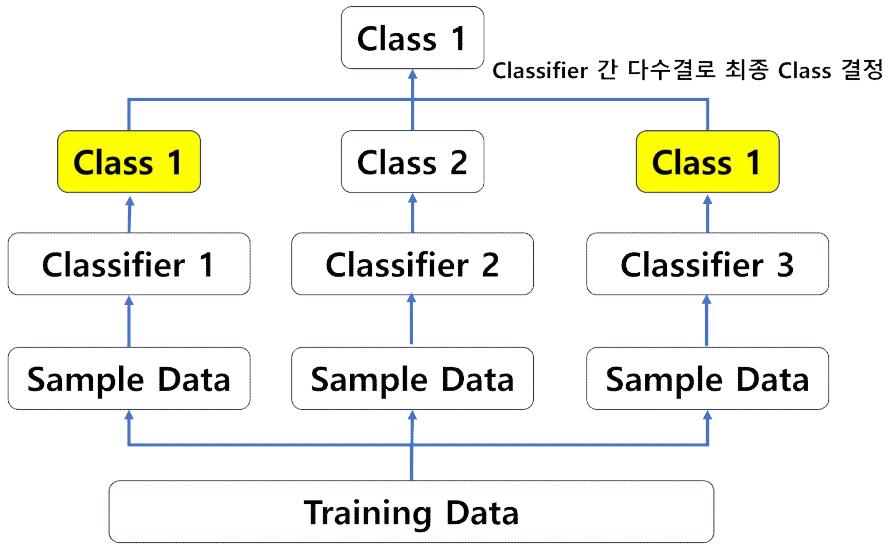


그림 4. 양상을 머신러닝 중 Hard Voting 학습 구조

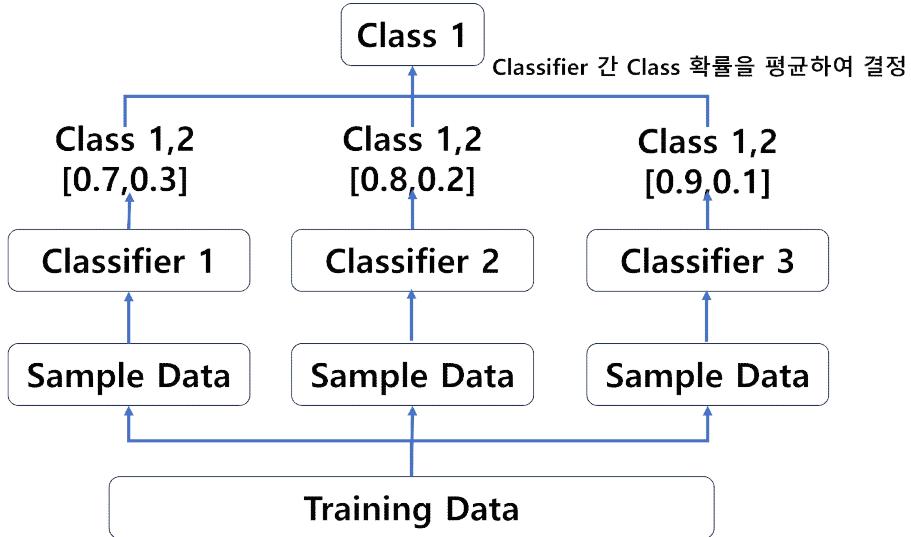


그림 5. 양상블 머신러닝 중 Soft Voting 학습 구조

본 논문에서는 BERT 모델 파인튜닝과 Voting과 Bagging 알고리즘을 이용한 양상별 머신러닝 기법의 융합을 통해 한국인 감정분석 모델을 설계한다. 대규모 언어 모델과 머신러닝 모델을 융합함으로 인해 문맥을 파악하여 상황에 따른 감정분석이 가능할 뿐만 아니라 문장 자체의 감정분석도 가능하다. 본 논문은 상황에 따른 감정분석과 문장 자체의 감정분석 결과 융합을 통해 더 정확한 감정분석이 가능하다.

III. 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 모델 설계

본 논문은 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 모델 설계를 제안한다. 그림 6은 제안하는 시스템의 동작 다이어그램이다. 제안하는 시스템은 크게 감정 딥러닝 모듈(DL_Emotioner), 머신러닝 모듈(ML_Emotioner), 최종 감정 계산 모듈(Mixture_Emotioner)로 구성되어 있다. 감정 딥러닝 모듈(DL_Emotioner)은 상황에 따른 감정분석을 위해 한국어 BERT 모델인 KoBERT 과 인 튜닝을 통해 감정 데이터를 학습할 수 있게 설계한다. 감정분석 머신러닝 모듈(ML_Emotioner)은 사용자 입력 데이터 자체에서의 직관적인 감정분석을 위해 양상을 머신러닝을 이용하여 감정 데이터를 학습할 수 있도록 설계한다. 최종 감정 계산 모듈(Mixture_Emotioner)은 DL_Emotioner와 ML_Emotioner에서 도출된 각 감정 예측 결과에 시그모이드 수식을 이용하여 최종 감정 class를 도출한다. 본 논문은 총 6가지 감정(기쁨, 당황, 분노, 불안, 상처, 슬픔) 카테고리를 이용한다. 6가지 감정은 기본 감정으로 미국의 심리학자 폴 에크만이 얼굴 표정을 기준으로 감정은 문화나 학습에 의한 것이 아니라 본능에 의한 것이라고 연구하였다[31].

본 논문은 딥러닝(DL_Emotioner)과 머신러닝(ML_Emotioner)을 이용한 감정분석 시스템을 제안함으로 상황에 따른 감정분석과 문장 자체의 직관적인 감정분석을 융합한 최종 결과를 도출한다. 제안하는 시스템은 사용자가 사용하고자 하는 상황에 따라 유연하게 학습할 수 있도록 모델을 설계한다. 따라서 아래 소개되는 응용시스템들은 각 상황에 맞게 최적화된 DL_Emotioner와 ML_Emotioner를 파인튜닝과 학습을 통해 시스템을 설계한다.

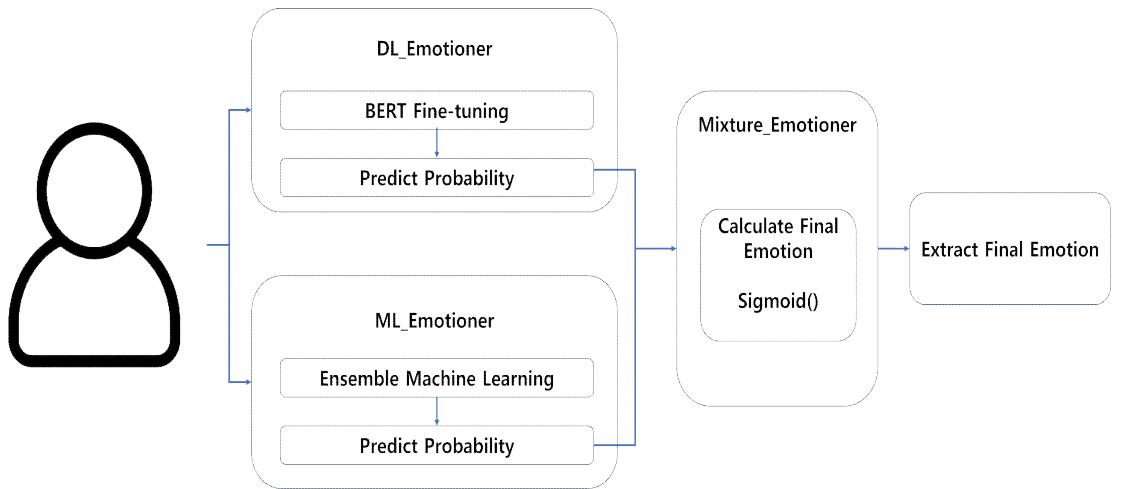


그림 6. 대규모 언어 모델(LLM)과 양상별 머신러닝 모델을 융합한 한국인 감정분석 모델

본 논문은 DL_Emotioner를 설계하기 위해서 대규모 언어 모델 중 문맥 파악에 높은 성능을 보이고 오픈소스로 공개한 KoBERT와 Llama 2를 비교하였다. KoBERT는 대용량 한국어 데이터로 BERT를 학습시킨 모델이다. Llama 2는 Meta AI에서 공개한 오픈소스이다. Llama 2는 다양한 가중치 모델 크기(7B, 13B, 70B)를 제공한다. 본 논문에서는 Llama 2-7B 모델을 사용하여 비교하였다. 실험 환경은 NVIDIA GeForce RTX 3080 Ti GPU 2개, GPU 내장 RAM 48GB, learning rate= 1e-4, Epoch 100으로 동일하게 지정하여 실험을 진행하였다. 본 논문은 학습의 성능 여부를 확인하기 위해 Train 데이터에 대한 Loss 값을 구한다. 본 논문은 동일한 조건에서 실험하였을 때 최종 결과 KoBERT는 Train Loss 0.001, Llama 2는 Train Loss 0.006 값을 보이는 것을 확인하였다. 따라서 본 논문에서 DL_Emotioner 모델은 BERT Fine-Tuning을 통해 설계한다.

IV. 응용시스템 개발

1. 단어의 감정적 요소를 포함하는 대규모 언어 모델(LLM)과 앙상블 머신러닝 모델을 융합한 한국인 감정분석 시스템

1) 단어의 감정적 요소를 포함하는 한국인 감정분석 시스템

본 논문은 단어의 감정적 요소를 포함하는 대규모 언어 모델(LLM)과 앙상블 머신러닝 모델을 융합한 한국인 감정분석 시스템을 제안한다. 제안된 시스템은 단어 자체에 포함한 감정을 고려함으로 인해 한국어의 특성을 고려할 수 있다. 그림 7은 제안하는 시스템의 동작 다이어그램이다.

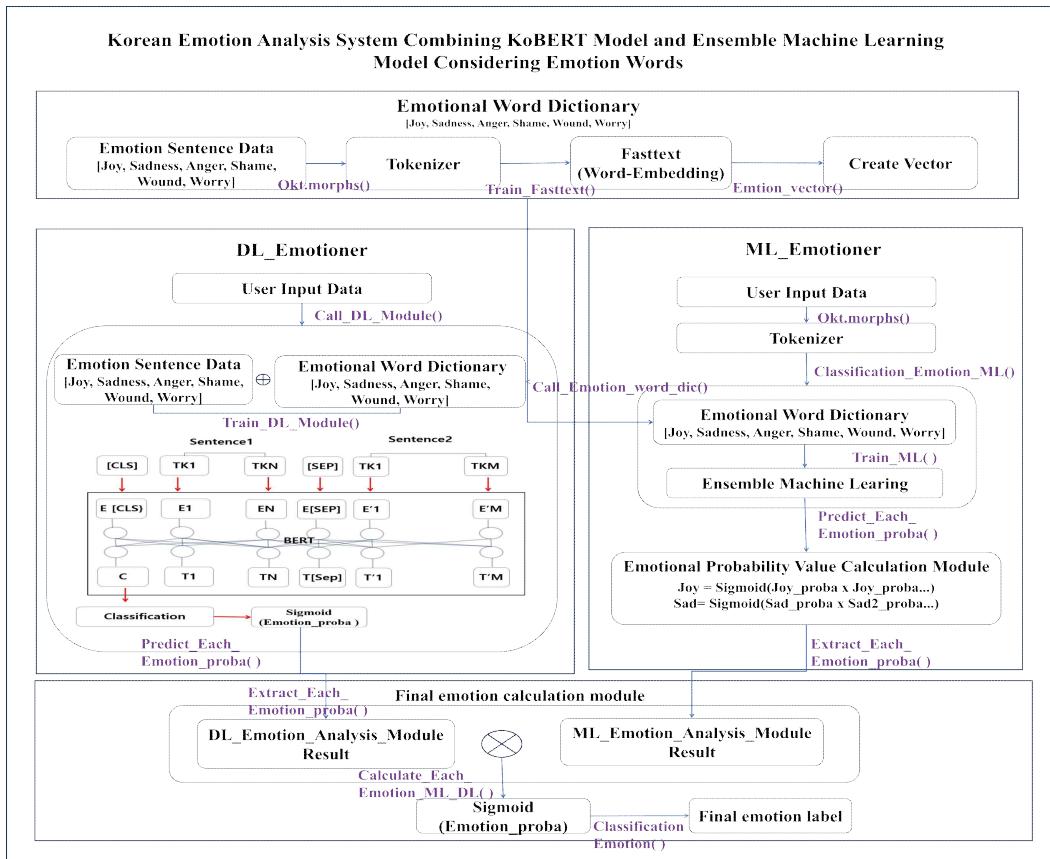


그림 7. 단어의 감정적 요소를 포함하는 KoBERT 모델과 앙상블 머신러닝 모델을 결합한 한국인 감정분석 시스템 동작 다이어그램

제안하는 시스템은 크게 감정 단어 사전, 감정 딥러닝 모듈(DL_Emotioner), 머신러닝 모듈(ML_Emotioner), 최종 감정 계산 모듈로 구성되어 있다. 감정 단어 사전은 감정에 따른 감정 단어 벡터 사전을 구축하여 단어의 감정적 요소를 파악한다. 감정 딥러닝 모듈(DL_Emotioner)은 과거 및 현재 문장의 문장 데이터를 식별하고 학습한다. 감정분석 머신러닝 모듈(ML_Emotioner)은 문장을 구성하는 각 단어의 감정을 분석한다. 제안된 감정분석 머신러닝 모듈(ML_Emotioner)은 각 단어에 대한 감정을 분석하고 분석 결과를 통합하여 결과를 도출한다. 제안된 시스템은 최종 감정 계산 모듈(Mixture_Emotioner)을 통해 도출된 감정 딥러닝 모듈(DL_Emotioner)과 감정 머신러닝 모듈(ML_Emotioner)의 각 감정에 대한 확률값을 가중치로 곱하여 최종 감정을 분석한다.

(1) 구축된 감정 사전

본 논문은 감정 사전을 구축하기 위해 AI_Hub[18]에서 제공하는 감정 대화 데이터 세트에서 [사람 응답 1]을 이용하여 구축한다. 표1은 학습에 사용하는 사람 응답 1 데이터 세트의 일부이다.

표 1. 감정 사전학습에 사용된 데이터

	감정 클래스	사람문장 1
1	기쁨	지금 기분이 너무 좋아
2	걱정	나는 내 고객과의 다음 계약이 무산될까 봐 걱정돼.
3	상처	어제 건강검진을 했는데 상태가 너무 안 좋았어.
4	불안	난 또 면접에서 떨어졌어.
5	분노	면접을 본 곳에서 거절당했다는 연락을 받았어.

제안하는 감정 사전은 Konlp의 Okt 형태소 분석기를 이용하여 형태소를 분석한다. Konlp의 Okt 형태소는 트위터에서 개발한 한국어 형태소 분석 오픈소스로 소셜 네트워크 대상으로 개발하여 비형식어 등을 잘 반영한다[19]. 감정 단어 사전은 수집한 데이터를 명사 단위로 형태소 분석 후 Fasttext 알고리즘을 이용하여 학습을 진행 후 감정 단어를 벡터화한다. 본 논문은 학습 계산량을 줄이기 위해 Fasttext 학습을 위해 하이퍼파라미터를 vector_size=2, window=5, min_count=1로 지정하여 학습하였다. Fasttext 학습 결과는 표2와 같다.

표 2. 감정 사전에서 감정 테이터를 Fasttext로 학습한 결과

감정 단어	Fasttext 학습을 통해 생성된 벡터
하	array([1.1001561, 1.1285814], dtype=float32)
웃음	array([0.26387474, 0.22757697], dtype=float32)
격리	array([0.24860919, 0.08018682], dtype=float32)
대인공포증	array([-0.12159092, 0.00394389], dtype=float32)

(2) 감정분석 머신러닝 모듈

본 논문은 제안한 감정분석 머신러닝 모듈(ML_Emotioner)을 통해 구축한 감정 단어 사전의 벡터 데이터를 이용하여 머신러닝 학습을 통해 감정을 분석한다. 본 논문은 양상을 머신러닝 알고리즘 중 Decision Tree 분류 머신러닝 모델 여러 개를 결합한 RandomForest 알고리즘을 사용한다[20]. 시스템에서 제안하는 ML_Emotioner은 사용자 문장을 입력받으면 사용자 문장을 토큰화한 후 문장에 사용된 각 단어의 감정들을 분석한다. 도출된 각 단어의 감정의 확률값을 정규화하기 위해 0~1 사이의 값으로 도출하는 Sigmoid 함수를 통해 ML_Emotioner 모듈을 통한 최종 감정을 분석한다. 사용된 Sigmoid 함수는 식 1과 같다[21].

$$ML_{Result}_{Sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

식 1. ML_Emotioner를 통해 나온 예측 확률값 정규화를 위해 사용되는 수식
(x : 각 감정 Class 별 도출되는 예측 확률값)

(3) 감정분석 딥러닝 모듈

본 논문은 문장과 맥락 속 감정을 분석하기 위해 BERT 모델을 파인 튜닝하는 감정 딥러닝 모듈 (DL_Emotioner)를 사용한다. 본 논문에서는 대규모 한국어 코퍼스로 학습한 KoBERT 모델을 미세 조정하여 감정을 분석한다[15]. 본 논문은 AI_Hub[18]의 사람문장 30,000개와 6가지 주요 감정 범주(슬픔, 분노, 행복, 상처, 당황, 불안) 데이터를 사용하여 학습한다. 사용된 데이터의 구성은 감정 단어 사전에 사용된 표1의 데이터와 동일하다. 본 논문에서는 KoBERT Fine tuning을 위해 반복 실험을 통해 최적의 값을 찾고, Hidden_size = 728, max_len = 32, learning_rate =

$1e-5$, $\text{log_interval} = 200$, $\text{epoch} = 500$ 으로 학습하였다. 제안하는 DL_Emotioner는 최종적으로 여섯 가지 감정 Class에 대한 확률값을 도출한다.

(4) 딥러닝 머신러닝 융합 모델

본 논문은 Mixture_Emotioner를 통해 구축한 딥러닝 감정 모듈과 머신러닝 감정 모듈을 바탕으로 최종 감정을 분석한다. 제안하는 융합 모델은 딥러닝과 머신러닝 감정분석 모듈을 통해 나온 감정 확률값을 곱한 후 $0\sim1$ 사이의 값으로 도출하는 Sigmoid 함수 통해 최종 감정을 분석한다. Sigmoid 함수는 식 1과 같다. 표3은 제안된 모듈을 통한 감정분석 결과를 보여준다.

표 3. 제안된 시스템을 통한 감정분석 결과

	사용자 입력	감정 클래스
1	하...오늘 너무 힘들다.	슬픔
2	하...오늘 너무 화가 나네요.	분노
3	친구랑 놀다가 다쳤어요.	슬픔
4	나는 숙제를 끝내지 못했습니다. 학교에 가기가 무서워요.	상처
5	주식은 절대 사지 말라고 했는데 몰래 하다가 망했어요.	불안

2) 실험 및 평가

본 논문에서는 편향되지 않는 감정 단어 사전 구축을 위해 감정별 데이터 수를 약 200개로 설정하였다. 본 논문에서는 양상을 머신러닝 중 최적의 양상을 머신러닝 알고리즘을 식별하였다. 실험을 위해 여러 분류 알고리즘을 결합하여 학습할 수 있는 투표 알고리즘을 통해 정확도를 도출하고 비교하였다. 그림 8은 단일 분류 머신러닝 알고리즘의 조합에 따른 정확도를 나타낸 그래프이다.

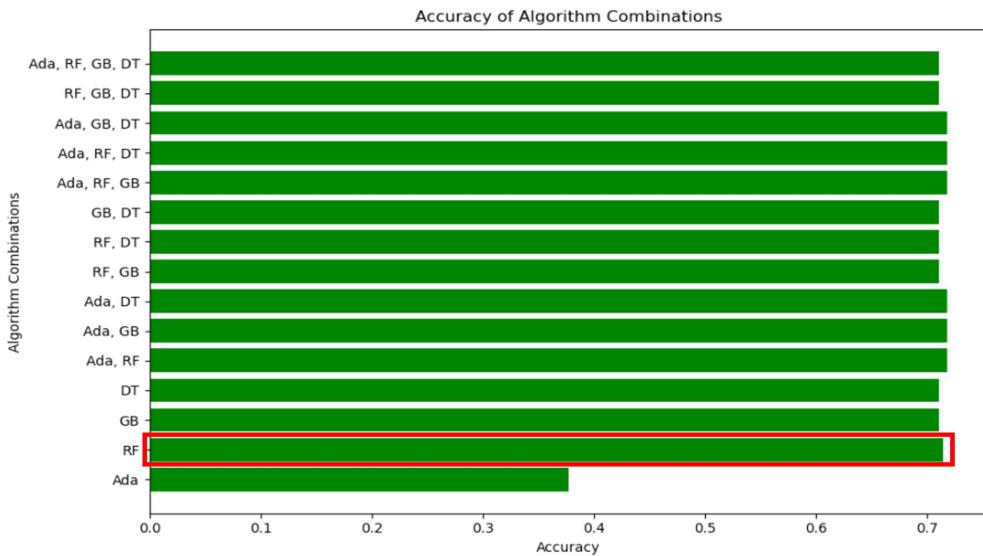


그림 8. 단일 분류 머신러닝 알고리즘의 조합에 따른 정확도

실험 결과, 본 논문은 RandomForest가 0.718로 다른 알고리즘 조합과 비교해 가장 높은 성능을 달성한 것을 확인하였다. 따라서 본 논문에서는 RandomForest를 이용하여 모델을 구축하였다. 본 논문에서는 Random Forest 알고리즘을 통해 학습한 결과, 학습 Accuracy = 0.718, Precision = 0.714, Recall = 0.714, F1-score = 0.708을 도출한다. 그림 9는 RandomForest 학습 후 생성된 혼동행렬이다.

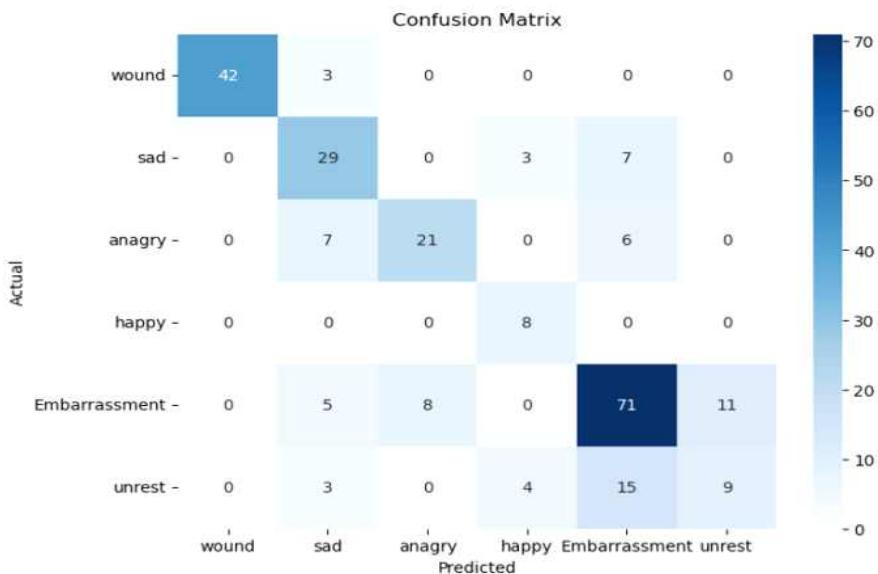


그림 9. Random Forest 학습 후 생성한 혼동행렬 그래프

본 논문에서는 딥러닝 감정분석 모듈(DL_Emotioner) 모델 학습의 정확도를 파악하기 위해 전체 데이터에서 정답인 데이터의 비율을 계산하는 Accuracy와 Loss 값을 계산하였다. 그 결과, 본 논문은 Train_Accuracy = 0.98, Test_Accuracy = 0.78, Loss = 0.0024를 확인하였다. 그림 10은 각 100 에포크에 대한 Train/Test 정확도 및 Loss 값을 그래프로 표현한 것이다.

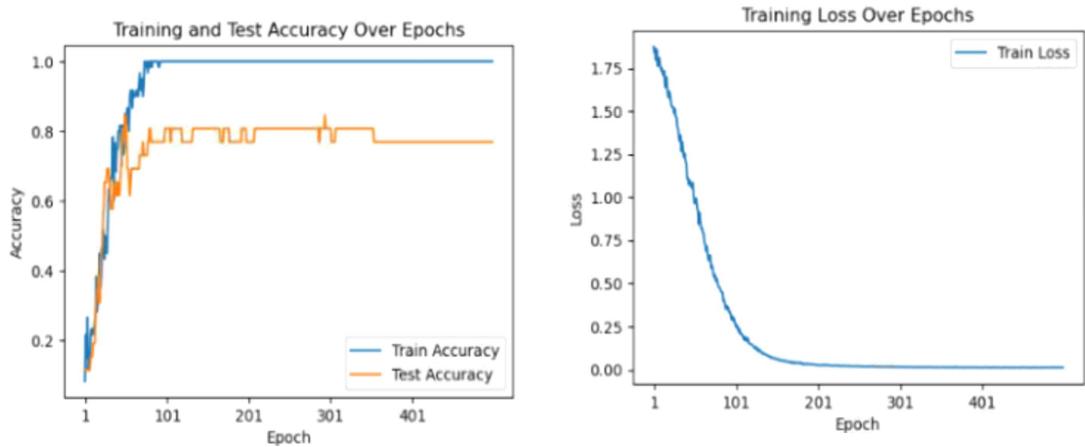


그림 10. 딥러닝 감정분석 모듈(DL_Emotioner) Train/Test 정확도 및 Loss 값

2. 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국 자폐 아동들의 감정분석 시스템

1) 한국 자폐 아동들의 감정분석 시스템

발달 장애는 사회적 관계, 의사소통, 인지 발달이 지연되거나 비정상적으로 나타난다. 발달 장애 유형 중 자폐아는 언어 및 의사소통 발달이 지연되는 것이 특징이다. 자폐아동은 반복적으로 단순한 언어와 행동을 통해 감정을 표현한다[10]. 본 논문은 반복적인 문장 혹은 단일 문장을 말하는 자폐 아동들의 감정분석을 위해 대규모 언어 모델(LLM)과 양상을 머신러닝을 결합한 감정분석 시스템을 설계한다. 본 논문은 한국정보화진흥원인 AI_Hub에서 제공하는 20,000개 이상의 감정 데이터 세트를 이용하여 모델을 구축하였다[18]. 한국정보화진흥원의 감성 데이터는 크게 6가지 카테고리('

기쁨', '당황', '분노', '불안', '상처', '슬픔') 감정_대분류, 사람문장1, 시스템 문장1로 구성된다. 본 논문에서는 사람문장 1과 시스템 문장 1을 사용한다. 또한, 본 논문은 슬픔 카테고리에는 상처 카테고리 포함했다. 본 논문은 분노 카테고리에 당황 카테고리를 포함했다. 따라서 본 논문은 총 4가지 감정 카테고리('기쁨', '불안', '분노', '슬픔')를 사용한다. 본 논문에서 제안한 한국 자폐 아동들의 감정분석 시스템 모델 다이어그램은 아래 그림 11과 같다.

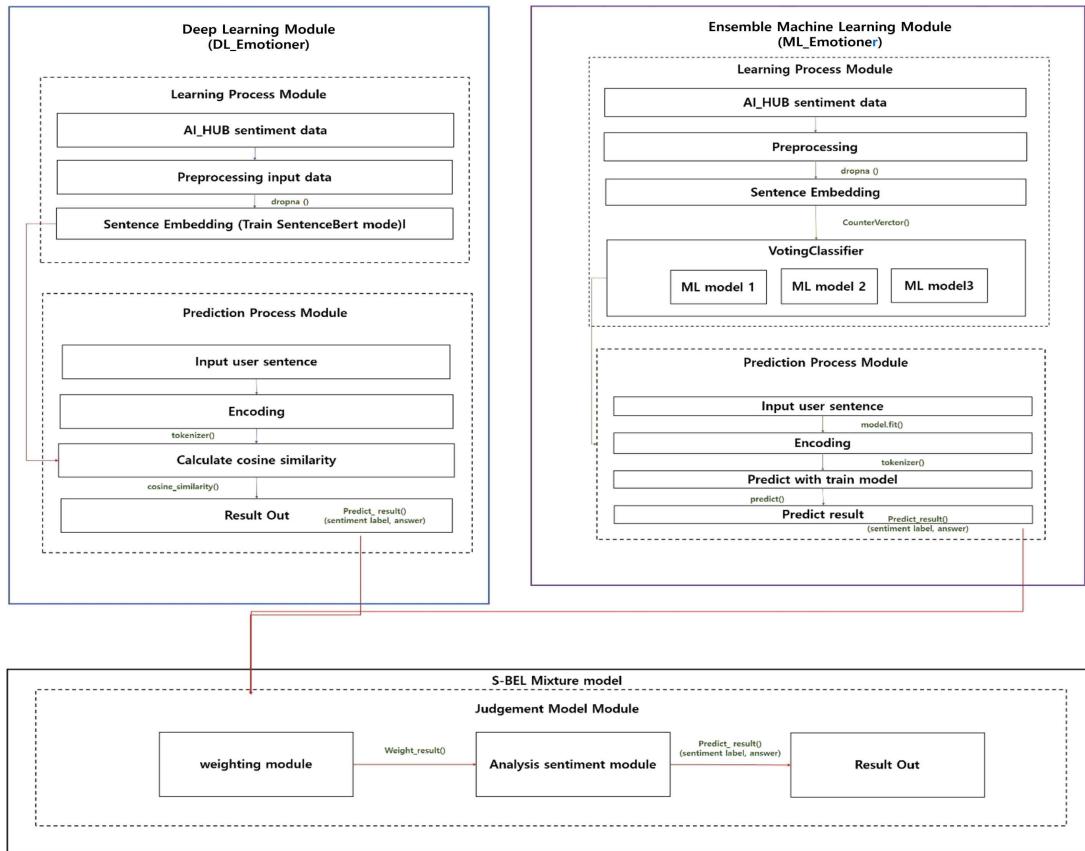


그림 11. SBERT와 양상을 머신러닝 결합한 자폐 아동들의 감정분석 시스템

제안된 모델은 Sentence Bert 기반 딥러닝 모델 (DL_Emotioner), 양상을 머신러닝 모델(ML_Emotioner), S-BEL Mixture 모델로 구성된다. 본 논문에서 제안하는 S-BEL Mixture 모델은 SBERT 기반 DL_Emotioner와 양상을 머신러닝 모델인 ML_Emotioner의 예측 결과를 활용한다. 제안하는 시스템은 S-BEL Mixture를 통해 예측된 결괏값을 최종 감정 결괏값으로 도출한다. SBERT 모델은 BERT 모델에 문장

유사성을 측정하는 STS 데이터 세트와 문장 간의 관계를 파악하는 NLI 데이터 세트를 통해 학습한다[12]. 본 논문에서의 DL_Emotioner 모듈은 사람문장 1과 감정_대분류 쌍으로 구성된 데이터를 특징값으로 사용하여 파인 튜닝한 SentenceBERT 모델을 학습합니다. 훈련된 SentenceBERT는 사용자 입력에 해당하는 예측을 만들기 위해 사용자가 입력하는 문장을 벡터화하는 인코딩을 진행합니다. 인코딩을 통해 벡터화된 문장은 훈련된 모델과의 코사인 유사도 계산을 통해 가장 가까운 문장과 감정을 예측합니다. 코사인 유사성은 수식 2와 같이 계산된다[22].

$$\cos(\theta) = \frac{A^*B}{\|A\|\|B\|}$$

수식 2. 코사인 유사도 수식

본 논문에서의 ML_Emotioner은 양상을 머신러닝 종류 중 VotingClassifier 모델을 사용하여 2개 이상의 단일 분류 머신러닝 모델을 사용합니다. 본 논문에서 구축한 VotingClassifier 모델은 XGBoost, RandomForest, MultinomialNB 모델을 사용합니다. Hard-Voting 모델은 다수 분류에 따른 각 분류기 모델의 결과 중 가장 많은 표를 얻은 클래스의 예측값을 확정합니다. Soft-Voting 모델은 각 분류기 예측에 대해 가장 높은 평균 확률을 갖는 클래스를 예측합니다[23]. 제안된 모델에는 Soft-Voting 모델을 적용하였다. 본 논문에서는 수집된 감정 데이터를 CounterVectorizer를 통해 단어 발생 횟수로 벡터화하여 문장을 만든다. 이후 파이프라인을 통해 MultinomialNB, RandomForest 및 XGBoost 모델을 VotingClassifier 모델로 학습한다. 제안된 ML_Emotioner은 사용자 입력 문장을 입력하여 사용자 입력에 대응하는 감정을 예측하는 과정을 진행한다. 입력된 문장의 감정 결과는 확률에 따른 모델의 예측을 통해 출력된다. 본 논문에서 제안하는 S-BEL Mixture 모듈의 가중치를 부여하는 공식은 아래의 수식 3과 같다.

$$S.BEL_w = W_{ms} * X_{mp} + (b_s - 1)$$

수식 3. S-BEL Mixture Module 가중치 수식

(S.BELw : Weight result value, Wms : ML Accuracy value of the model, Xmp : Probability value measured through ML module, bs: Similarity measure of SBERT Model)

수식 3에서 b_s는 SBERT 모델의 유사성 측정값, W_ms는 양상을 학습 모델의 정확도 값, X_mp는 양상을 학습 모델이 측정한 확률값이다. 수식3은 W_ms와 X_mp의

곱을 통해 정확도와 예측 확률의 상관관계를 분석한다. 또한, 수식 3은 $b_s - 1$ 값을 통한 편향 값을 보여줍니다. 식4는 0과 1 사이의 스케일링을 위해 시그모이드 함수 공식을 적용했습니다[27].

$$S.BEL_w = \frac{1}{e^{-(S.BEL_w)}}$$

수식 4. S-BEL Mixture 모델의 가중치 스케일링 공식

제안된 S-BEL Mixture 모델은 임곗값을 사용하여 결정 모듈을 설계한다. 본 논문에서는 0.1부터 1.0까지의 임곗값을 지정하여 정확도 비교를 통해 적절한 임곗값을 찾는 방법을 사용하였다. 그림 12는 임곗값 0.5가 가장 높은 정확도를 도출했음을 보여준다.

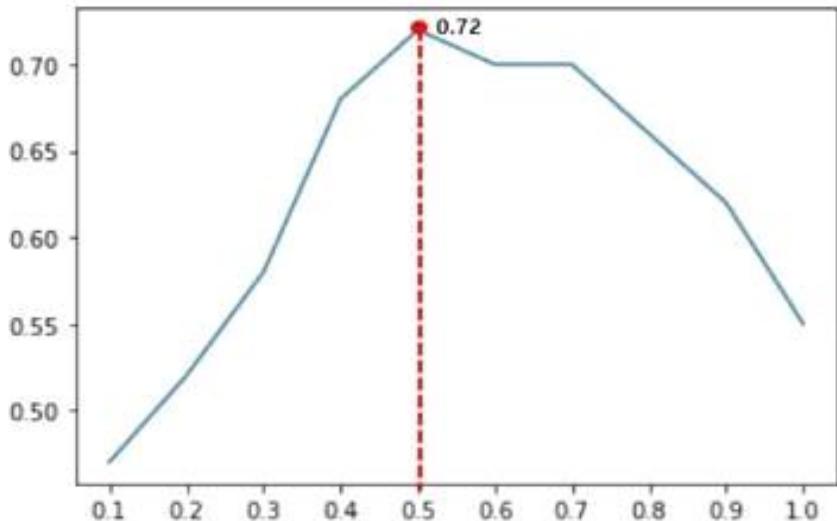


그림 12. 임곗값에 따른 성능 평가 결과

따라서 제안된 S-BEL Mixture 모델은 결정 모듈을 통해 S-BEL Mixture의 가중치 값이 지정된 임곗값(0.5)보다 높은지 낮은지 여부를 검증한다. 결정 모듈의 결정 결과가 지정된 임곗값 이상이면 제안 모델이 예측한 감정에 대응하는 감정 라벨과 챗봇 형태의 답변이 출력된다. 반대로, 결정 모듈의 결정 결과가 지정된 임곗값보다 작은 경우에는 결Wat값이 출력되지 않는다.

2) 실험 및 평가

본 논문에서는 머신러닝 분류 모델과 제안 모델의 정확도를 그림 13과 같이 비교한다. 본 논문에서는 학습 데이터와 테스트 데이터 세트를 7:3 비율로 나누고 전체 샘플 수에서 정답 데이터의 비율을 확인하는 정확도를 측정 방법을 이용하여 성능을 측정하였다. 실험 결과, 각 단일 분류 머신러닝 알고리즘을 활용하여 감성 분석을 진행할 때보다 양상을 학습을 활용하여 진행할 때 정확도가 더 높았다. 또한, 제안된 S-BEL Mixture 모델이 다른 비교 모델에 비해 약 93%의 가장 높은 정확도를 달성하였다.

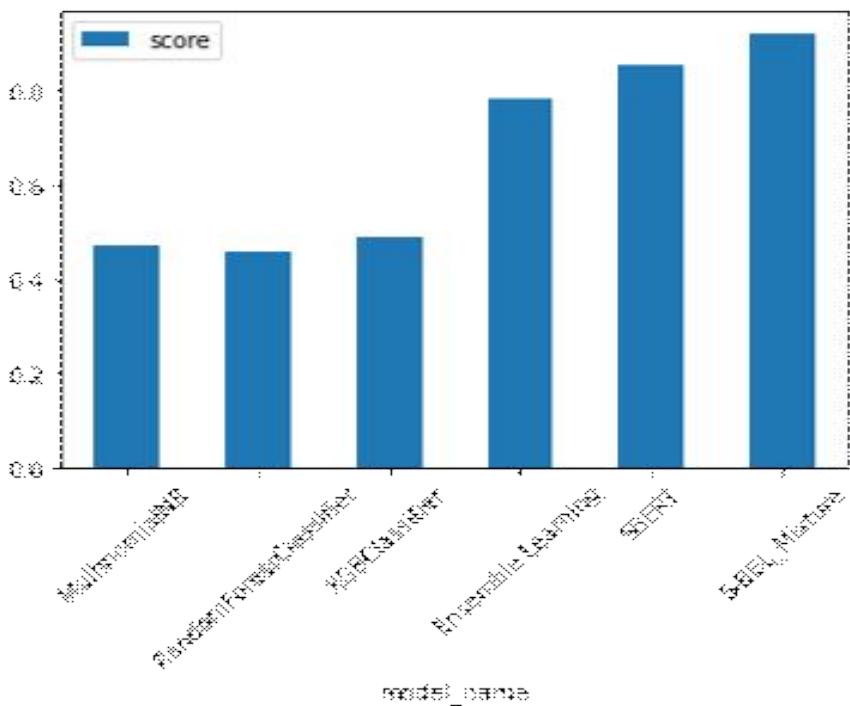


그림 13. 감정분석 모델 정확도 비교 벤치마크

실험을 위해 S-BEL Mixture 시스템의 챗봇 형 응답의 정확도를 측정하기 위해 BLEU 및 Cosine-Similarity 평가를 활용했다. BLEU(Bilingual Evaluation Understudy)는 기계 번역 시스템의 성능을 평가하는 방법 중 하나이다[24]. BLEU는 기계번역 시스템의 결과가 실제 결과와 얼마나 유사한지를 비교하여 성능을 측정한다. BLEU 평가 방식은 점수가 높을수록 성능이 좋다는 의미이다[24]. 코사인-유사성은 생성된 문장과 정답 문장 간의 유사성을 측정한다. 코사인 유사성은 두 벡터의 각도를 통해

측정되며 범위는 -1에서 +1까지이고, +1에 가까울수록 유사도가 가장 높다[25].

제안된 평가 방법을 검증하기 위해 각 데이터에 대한 BLEU 점수와 코사인 유사성 점수를 비교 분석하였다. 그림 14부터 19까지는 테스트 데이터 세트 수에 따른 각 알고리즘의 BLEU 및 Cosine 유사성 점수를 나타낸 그래프이다. 그림 14는 S-BEL Mixture 모델에 대한 BLEU 점수 및 코사인 유사성 점수 그래프입니다. 그림 15는 MultinomialNB, RandomForestClassifier, XGBoost로 구성된 Ensemble Model에 대한 BLEU 점수와 Cosine 유사성 점수 그래프이다. 그림 16은 MultinomialNB와 RandomForestClassifier로 구성된 Ensemble Model에 대한 BLEU 점수와 Cosine 유사성 점수 그래프이다. 그림 17은 MultinomialNB, XGBoost로 구성된 Ensemble Model에 대한 BLEU 점수와 Cosine 유사성 점수 그래프이다. 그림 18은 RandomForestClassifier, XGBoost로 구성된 Ensemble Model에 대한 BLEU 점수와 Cosine 유사성 점수 그래프이다. 그림 19는 S-BEL Mixture 모델의 BLEU 점수와 코사인 유사성 점수 간의 상관관계를 보여준다. 그림 19의 오른쪽 히트맵은 Pearson 상관 계수를 사용하여 S-BEL Mixture 모델의 BLEU 점수와 코사인 유사성 점수 간의 상관관계를 보여준다. 피어슨 상관 계수는 두 변수 간의 선형 관계를 나타냅니다. 피어슨 상관 계수는 상관 계수 값이 1에 가까울수록 두 변수 사이의 관계가 더 높다는 것을 나타냅니다[26].

그림 14부터 19까지는 데이터 수에 따라 평가 점수가 달라지는 것을 보여준다. 정답 텍스트는 BLEU 및 Cosine 유사성 점수에 큰 영향을 미치기 때문에 테스트 데이터에서 정답에 없는 단어를 사용하여 답을 생성하는 경우 정확도가 감소한다. 그림 19는 제안된 S-BEL Mixture_Emotioner 모델의 BLEU 점수와 코사인 유사성 점수 간의 상관관계를 보여준다. 오른쪽의 히트맵 그래프를 보면 BLEU 점수와 Cosine 유사성 점수가 0.88의 높은 상관관계를 가지고 있는 것을 알 수 있다. 히트맵 그래프는 BLEU 점수와 Cosine 유사성 점수가 비슷한 방식으로 점수를 도출한다는 것을 의미한다. 따라서 본 논문에서 제안하는 검증 방법은 신뢰성을 갖는다.



그림 14. S-BEL Mixture Model BLEU, Cosine-Similarity Score

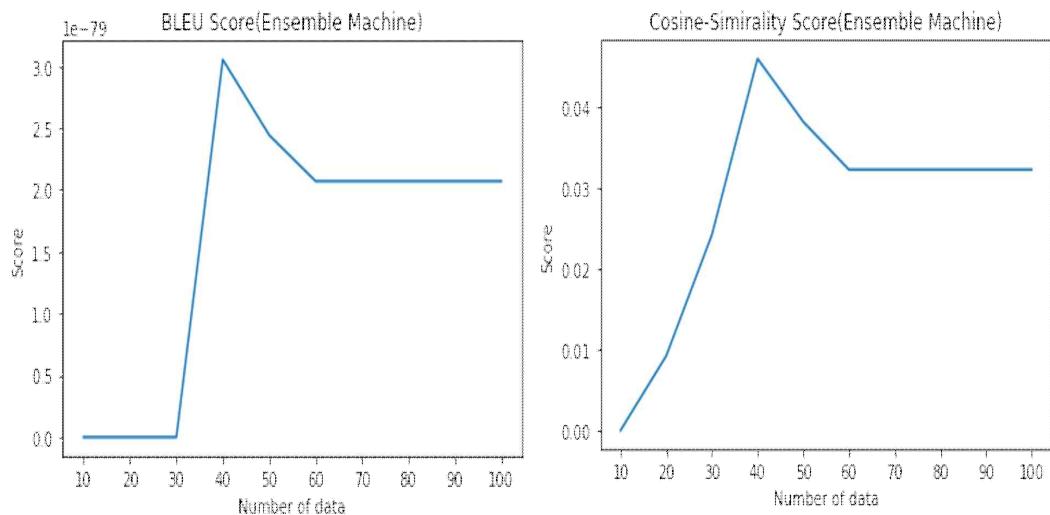


그림 15. Ensemble Machine (MultinomialNB, RandomForestClassifier, XGBoost)
BLEU, Cosine-Similarity Score

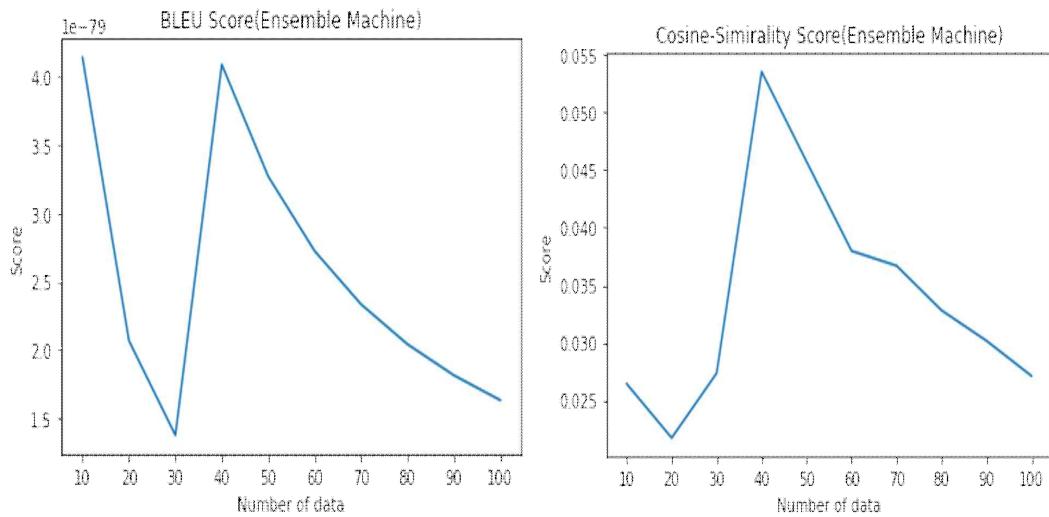


그림 16. Ensemble Machine (MultinomialNB, RandomForestClassifier) BLEU, Cosine Similarity Score

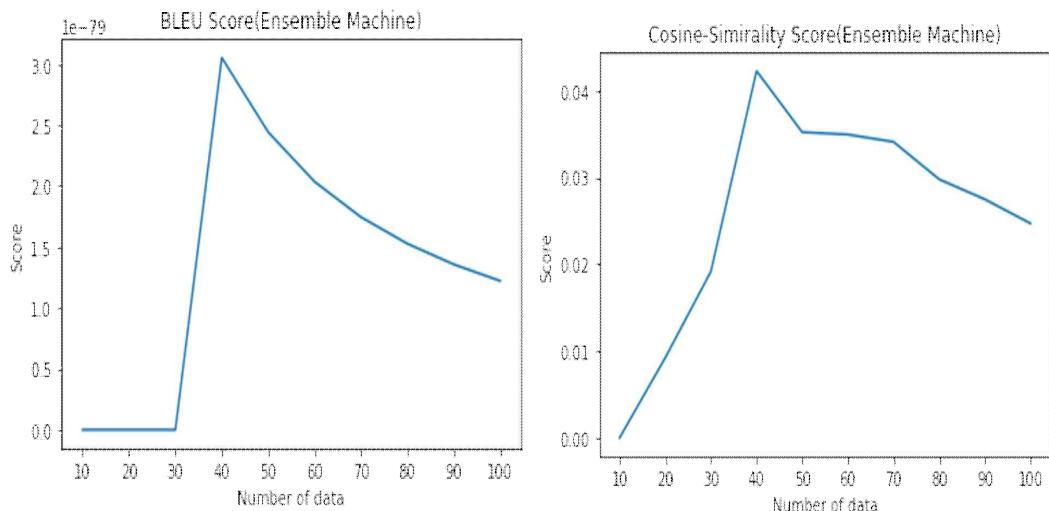


그림 17. Ensemble Machine (MultinomialNB, XGBoost) BLEU, Cosine-Similarity Score

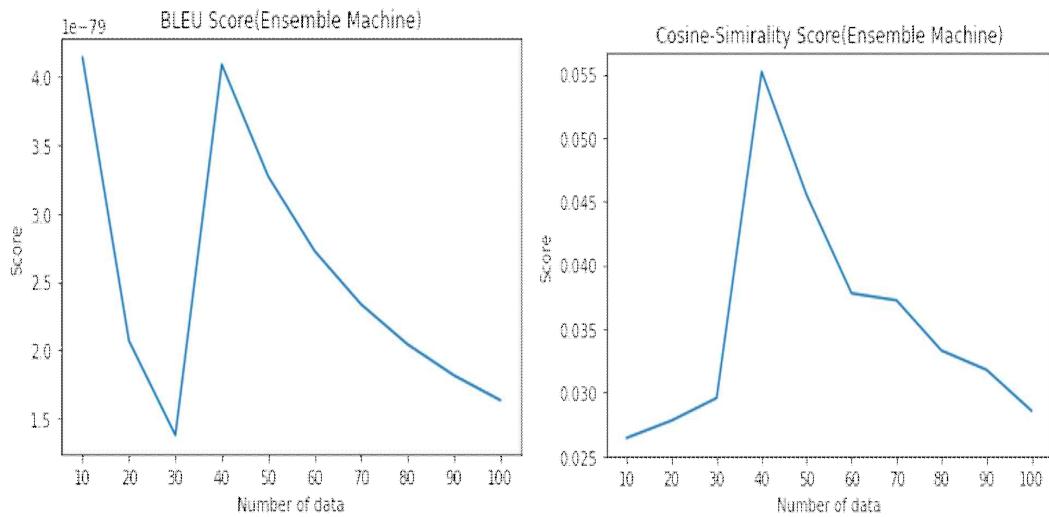


그림 18. Ensemble Machine (RandomForestClassifier, XGBoost) BLEU, Cosine Similarity Score

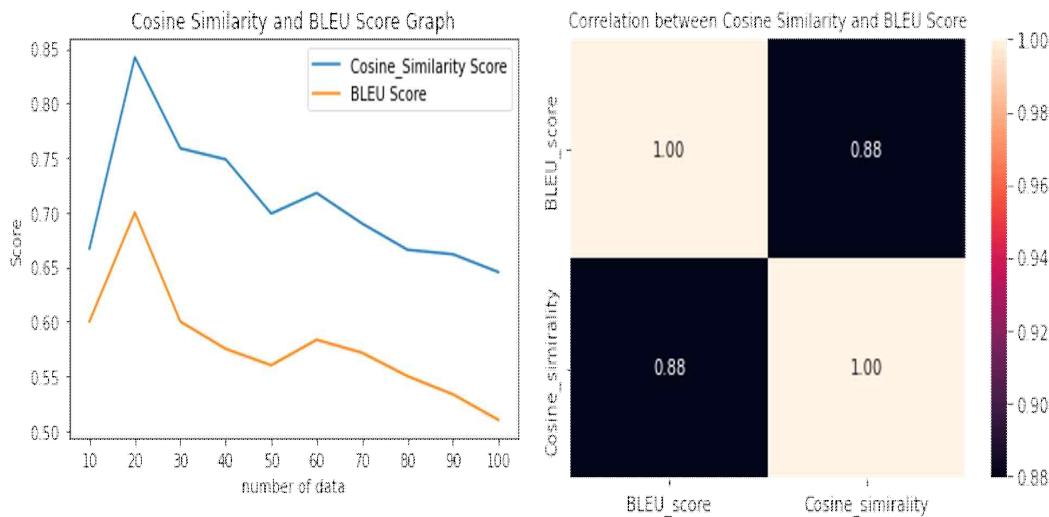


그림 19. Cosine Similarity Score와 BLEU 점수 그래프의 상관관계

본 논문에서는 평가검증 방법을 통해 가장 높은 점수를 받은 60개의 감정 문장 테스트 데이터 세트를 평가하였다. 실험 결과, 표 4와 같이 제안한 S-BEL Mixture 모델은 BLEU 값 0.593, Cosine-Similarity 0.712로 모든 성능 평가에서 높은 성능을 도출함을 확인할 수 있다.

표 4. Measurement of the accuracy of each system's chatbot-type response

System name	BLEU Score	Cosine-Similarity Score
S-BEL Mixture system	0.593	0.712
Ensemble Machine (MultinomialNB, RandomForestClassifier, xgboost)	0.020	0.032 (1e-79)
Ensemble Machine (MultinomialNB, RandomForestClassifier)	0.016	0.027 (1e-79)
Ensemble Machine (MultinomialNB, xgboost)	0.011	0.024 (1e-79)
Ensemble Machine (RandomForestClassifier, xgboost)	0.016	0.028 (1e-79)

아래 표 5는 제안된 S-BEL 혼합 모델 시스템의 샘플 결과이다. 결과 샘플을 통해 본 논문에서는 사용자가 입력한 문장에 대한 실제 감정 라벨이 제안된 혼합 모델이 예측한 감정 라벨과 일치하는지 확인하였다.

표 5. Experience Result (Excerpts of some sentences from the test data)

	입력 문장	실제 감정 라벨	감정 라벨 예측	챗봇 형태의 답변
1	슬퍼	슬픔	슬픔	슬프시군요.
2	정말 짜증나	분노	분노	화가 나셨군요
3	화가 나.	분노	분노	매우 화가 나셨군요
4	기뻐.	기쁨	기쁨	오 행복하시군요
5	행복한 결혼생활을 하고 계시나요?	기쁨	기쁨	결혼하고 나서 생활이 너무 편해졌군요

표 5는 입력 문장에 따른 실제 감정 레이블과 예측 감정 레이블이 거의 동일함을 보여줍니다. 또한, 제안 모델은 '화난다.', '행복하다' 등의 단순 문장의 실제 감정 라벨이 예측된 감정 라벨과 일치함을 확인했다. 따라서 제안된 모델은 챗봇 스타일의 적절한 응답 출력과 감정 라벨 예측이 가능하다.

3. 대규모 언어 모델(LLM)과 앙상블 머신러닝 모델을 융합한 한국인 감정분석 시스템을 이용한 선택적 Llama2 모델 감정분석 챗봇 시스템

1) 한국인 감정분석 시스템을 이용한 챗봇 시스템

본 논문은 감정분석 챗봇 시스템 성능 향상을 위한 KoBERT와 앙상블 머신러닝 모델을 결합한 감정분석 시스템과 선택적 Llama 2 모델 설계한다. 본 논문은 감정분석 챗봇의 성능 향상을 위해 설계되었다. 그럼 20은 제안하는 모델의 전체적인 동작 다이어그램이다.

제안하는 시스템은 감정분석 모듈, 감정 카테고리 선택기, 선택적 Llama2 챗봇 모듈로 구성한다. 감정분석 모듈은 사용자 입력 대화 문장을 통해 3가지 감정(슬픔, 기쁨, 분노)에 대해 분석하고 감정에 대한 확률값을 도출한다. 감정 카테고리 선택기는 감정 모듈에서 도출된 확률값을 바탕으로 문장 내에 포함된 감정을 파악하고 최종 감정을 선택하는 역할을 한다. 선택적 Llama2 챗봇 모듈은 감정 카테고리 선택기에서 도출된 최종 감정을 바탕으로 감정별로 학습한 Llama2 챗봇 모델을 선택하고 선택한 모델에서 챗봇형 답변을 도출한다.

KoBERT와 앙상블 머신러닝 모델을 결합한 감정분석 시스템 모듈은 사용자의 언어적 문장에서 감정을 분석한다. 제안하는 시스템은 AI_Hub[18]에서 제공하는 감성 대화 말뭉치 데이터 중 사람문장 1, 감정_대분류를 사용하여 학습한다. 사용하는 데이터의 구성은 표 6과 같다. 본 논문은 감정_대분류 6가지(슬픔, 기쁨, 분노, 상처, 불안, 당황) 중 가장 대표적인 감정 3가지(슬픔, 기쁨, 분노) 데이터 7,000개를 사용하여 학습하였다. 본 논문은 KoBERT 사전학습 모델 파인 튜닝 후 학습을 통해 DL_Emotioner 모듈을 설계하였다. KoBERT는 양방향을 통해 문맥 파악이 가능하다[6,15]. 제안하는 시스템은 앙상블 머신러닝 중 VotingClassifier 모델로 ML_Emotioner Module을 설계하였다. 제안한 시스템은 XGBoost, RandomForest, MultinomialNB 모델을 사용하여 Soft Voting Ensemble Machine Learning을 학습한다. Analysis Emotion Module은 Mixture_Emotioner를 통해 DL_Emotioner와 ML_Emotioner 모델을 융합하여 최종 감정 결과값을 도출한다. 본 논문은 학습한 Analysis Emotion Module을 이용하여 사용자가 대화 내용을 입력하면 해당 대화 내용의 감정을 분석한다. 제안하는 시스템은 학습에 사용한 슬픔, 기쁨, 분노 3가지 감정에 대한 예측 확률값을 도출한다. 감정분석 모듈을 통한 예측 감정 확률값은 표 7의 예측 감정 확률값과 같다.

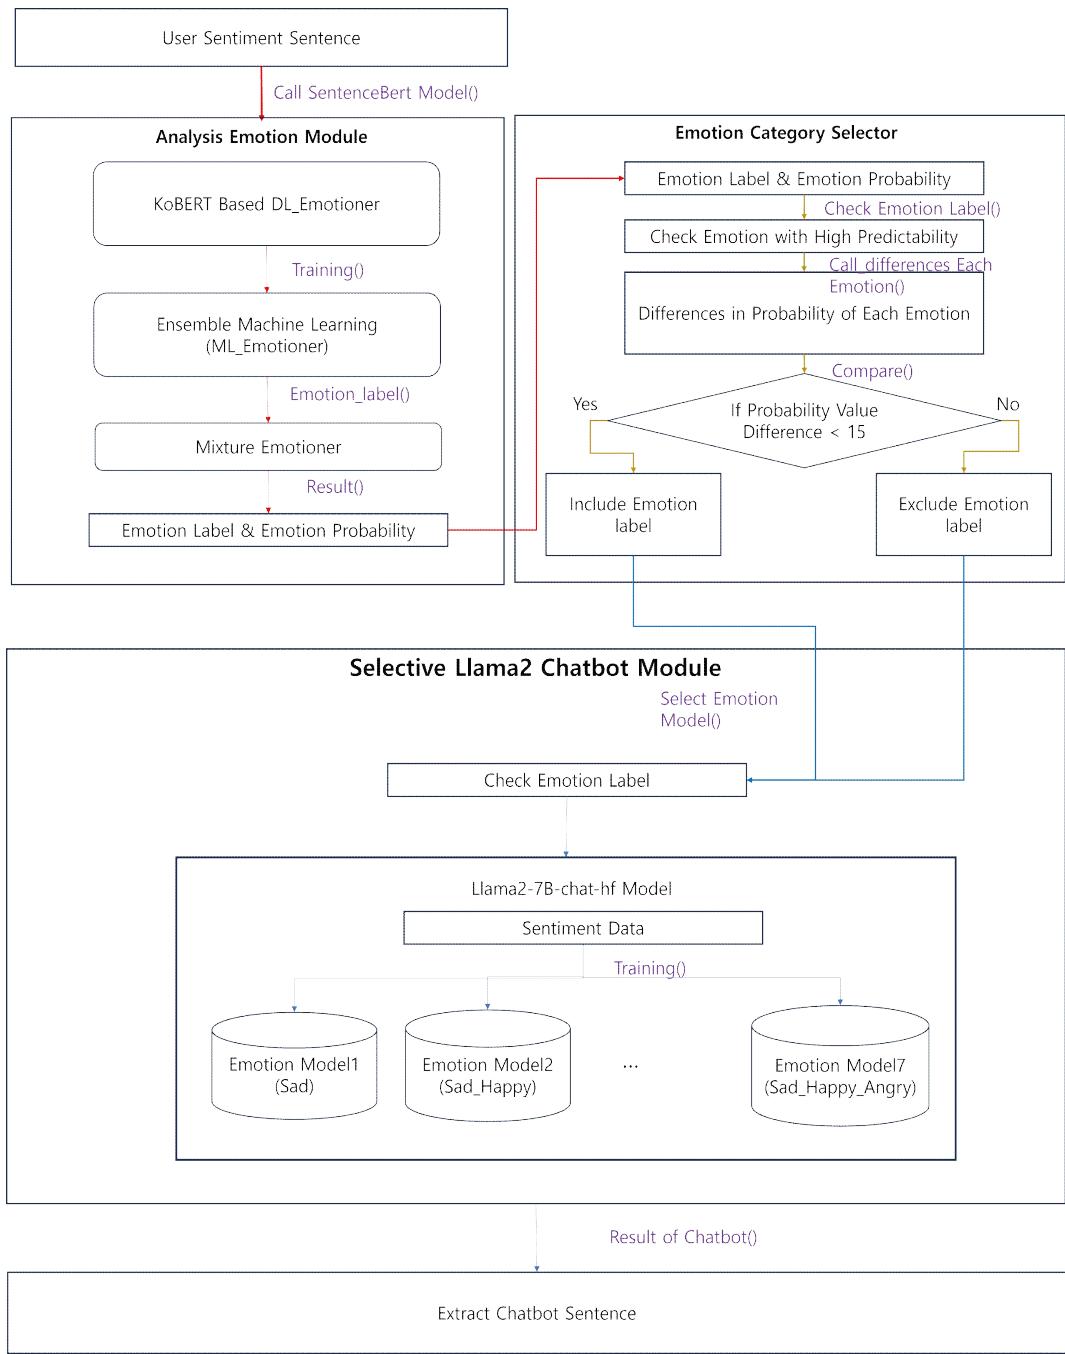


그림 20. 감정분석 챗봇 시스템 성능 향상을 위한 KoBERT 기반 감정 분류기와 선택적 Llama 2 모델 다이어그램

표 6. 사용하는 데이터 구성

	사람문장 1	시스템 응답 1	감정_대분류
1	학교에서 애들이 나 피하는 데 내가 한 말 때문에 그런 거 같아	학교에서 따돌림을 겪고 계시는군요.	슬픔
2	이번 주에 친한 친구의 생일이 있어서 깜짝 파티를 열어주고 싶어.	친한 친구분의 생일 때 깜짝 파티를 열어주고 싶군요	기쁨
3	내 장래 희망에 대해서 함부로 떠드는 친구에게 모멸감을 느꼈어.	그런 일이 생겨서 많이 화가 나시겠어요.	분노
4	어려운 프로젝트를 진행 중인데 날 응원해주는 사람이 한 명도 없어서 너무 슬프다.	나를 응원하는 사람이 없어서 슬프시군요	슬픔
5	사무실 사람들이 나를 일부러 무시하는 것 같아 화가 나	사무실 사람들 때문에 기분이 안 좋으시겠어요.	분노

표 7. 감정분석 모듈 결과

	사람문장 1	예측 감정 확률 [슬픔, 기쁨, 분노]	예측 감정
1	내 친구가 나 대신 나섰다가 폭행을 당했다는 소식을 듣고 심장이 멎는 줄 알았어!	[10.12551, -4.98441, -4.325249]	슬픔_분노
2	오늘 선생님이 내가 괴롭힘당하고 있는 걸 몰랐던 것에 대해 사과하셨어.	[8.780641, -1.4066051, -6.2898874]	기쁨_슬픔
3	며칠 전에 내가 다른 반 애한테 맞고 있었는데 우리 반 반장이 나타나서 말려줬어.	[-5.4003463, 10.35224, -3.6633172]	기쁨_분노
4	오늘 친구랑 속 깊은 얘기를 나눴어.	[-4.345507, 10.8411875, -4.700371]	기쁨
5	기분이 나빠도 그냥 넘어가는 내가 바보 같아서 슬퍼.	[10.155785, -5.164654, -4.1531515]	슬픔_분노

감정 카테고리 선택기는 사용한 감정_대분류에 따라 무응답 경우를 제외하고 경우의 수를 생성한다. 생성한 감정_대분류의 경우의 수는 [슬픔, 기쁨, 분노, 슬픔_기쁨, 슬픔_분노, 기쁨_분노, 슬픔_기쁨_분노] 총 7가지로 생성된다. 본 논문에서는 경우의 수에 따라 생성한 7가지 감정을 감정 카테고리라고 정의한다. 감정 카테고리 선택기는 Analysis Emotion Module에서 도출한 예측 감정 확률값을 통해 각 예측 감정 확률값 간의 차이를 구한다. 제안하는 시스템은 가장 예측 확률값이 큰 감정 카테고리

를 기준으로 각 확률값의 차이를 구한다. 예를 들면, 슬픔이 가장 큰 예측 확률이 나왔을 때 제안하는 시스템은 기쁨_슬픔(happy_sad), 슬픔_분노(sad_angry)의 예측 확률값 차이를 구한다. 제안하는 시스템은 test 데이터의 감정 예측 확률값의 중간값인 15를 기준으로 최종 감정을 구한다. 만약 기쁨_슬픈(happy_sad) 감정 예측 확률값의 차이가 15 이하이고 슬픔_분노(sad_angry)의 감정 예측 확률값이 15 이상이면 예측 문장의 감정이 슬픔뿐만 아니라 기쁨이라는 감정도 도출될 수 있다고 인지하고 분노에 대한 감정은 제외한 기쁨_슬픔(happy_sad)을 도출한다. 표8은 감정 카테고리 선택 기의 알고리즘 의사 코드이다.

표 8. 감정 카테고리 선택기 알고리즘 의사 코드

감정 카테고리 선택기 알고리즘 의사 코드
<pre> 감정 결과를 저장하는 emotion_result 리스트 선언 SET 감정 임곗값 is 15 CALL 감정 카테고리 선택기 함수 호출 IF 확률값 최댓값이 "슬픔" 클래스일 때: IF 슬픔_분노가 감정 임곗값 이하 혹은 행복_슬픔이 감정 임곗값 이하일 때 IF 슬픔_분노가 감정 임곗값 이하이고 행복_슬픔이 감정 임곗값 이하일 때 THEN "all" 감정 클래스를 emotion_result emotion_result 리스트에 추가 ELSE IF 슬픔_분노가 감정 임곗값 이하이고 기쁨_슬픔이 감정 임곗값 이상일 때 THEN "슬픔_분노" 감정 클래스를 emotion_result emotion_result 리스트에 추가 ELSE IF 슬픔_분노가 감정 임곗값 이상이고 기쁨_슬픔이 감정 임곗값 이하일 때 THEN "기쁨_슬픔" 감정 클래스를 emotion_result emotion_result 리스트에 추가 ELSE THEN "슬픔" 감정 클래스를 emotion_result emotion_result 리스트에 추가 IF 확률값 최댓값이 "기쁨" 클래스일 때: IF 기쁨_분노가 감정 임곗값 이하 혹은 기쁨_슬픔이 감정 임곗값 이하일 때 IF 기쁨_분노가 감정 임곗값 이하이고 기쁨_슬픔이 감정 임곗값 이하일 때 THEN "all" 감정 클래스를 emotion_result emotion_result 리스트에 추가 ELSE IF 기쁨_분노가 감정 임곗값 이하이고 기쁨_슬픔이 감정 임곗값 이상일 때 THEN "기쁨_분노" 감정 클래스를 emotion_result emotion_result 리스트에 추가 ELSE IF 기쁨_분노가 감정 임곗값 이상이고 기쁨_슬픔이 감정 임곗값 이하일 때 THEN "기쁨_슬픔" 감정 클래스를 emotion_result emotion_result 리스트에 추가 ELSE THEN "기쁨" 감정 클래스를 emotion_result emotion_result 리스트에 추가 </pre>

```

IF 확률값 최댓값이 "분노" 클래스일 때:
    IF 기쁨_분노가 감정 임곗값 이하 혹은 슬픔_분노가 감정 임곗값 이하일 때
        IF 기쁨_분노가 감정 임곗값 이하이고 슬픔_분노가 감정 임곗값 이하일 때
            THEN "all" 감정 클래스를 emotion_result emotion_result 리스트에 추가
        ELSE IF 기쁨_분노가 감정 임곗값 이하이고 슬픔_분노가 감정 임곗값 이상일 때
            THEN "기쁨_분노" 감정 클래스를 emotion_result emotion_result 리스트에 추가
        ELSE IF 기쁨_분노가 감정 임곗값 이상이고 슬픔_분노가 감정 임곗값 이하일 때
            THEN "슬픔_분노" 감정 클래스를 emotion_result emotion_result 리스트에 추가
    ELSE
        THEN "분노" 감정 클래스를 emotion_result emotion_result 리스트에 추가

```

제안된 시스템의 예측 감정분석 결과는 표7의 예측 감정과 같이 도출한다. 선택적 Llama 2 챗봇 모듈은 사용자의 대화 내용에 적절한 감정적 챗봇 답변을 도출한다. 선택적 Llama 2 챗봇 모듈은 표6과 같이 수집한 감성 대화 말뭉치 데이터 중 사람문장 1, 시스템 응답 1을 사용한다. 선택적 Llama 2 챗봇 모듈은 감정 카테고리 선택기에서 구축한 감정 카테고리에 따른 감정 데이터를 구성한 후 Llama 2-chat-7B 모델을 파인튜닝과 모델 경량화를 위한 4bit 양자화를 통해 학습한다. Llama 2는 대규모 언어 모델로 GPT의 트랜스포머 모델을 개선한 모델이다[16]. Llama 2는 모델 크기(7B, 13B, 70B)에 따른 모델이 존재하며 Llama 2-chat-7B는 인간 피드백 기반 강화학습 등의 학습으로 챗봇과 같이 대화 흐름을 파악하는 모델에 높은 정확도를 보인다[16]. 제안하는 시스템은 감정 카테고리별 Llama 2-chat-7B로 학습된 각 챗봇 모델 중 감정 카테고리 선택기에서 도출한 감정에 해당하는 모델을 선택한다. 제안한 시스템은 선택된 모델을 통해 감정 챗봇 답변을 도출한다.

2) 실험 및 평가

본 논문에서는 학습 정확도, 예측 정확도, 손실을 주요 지표로 사용하여 제안 시스템의 성능을 평가한다. 또한, 감성 분석 모듈과 선택적 Llama2 챗봇 모델의 성능은 학습 정확도, 재현율, 손실을 통해 평가한다. 본 논문은 KoBERT 기반 감정분석 모듈의 성능 확인을 위해 수식 5의 정확도 수식을 이용하였다. 수식 5의 y 는 정답 값, y' 는 예측값, N 은 전체 데이터의 개수를 나타낸다[29].

$$Accuracy(y, y') = \frac{1}{N} \sum_{i=0}^{n-1} 1(y'_i = y_i)$$

수식 5. 학습 Accuracy 수식

실험 결과, 제안하는 KoBERT 기반 감정분석 모듈의 학습 정확도는 1.0, Loss 값은 약 0.001, 예측 정확도는 약 84%의 정확도가 도출되었다. 그림 21은 왼쪽은 학습/예측 정확도를, 오른쪽은 학습에 대한 Loss 값을 나타낸 그래프이다.

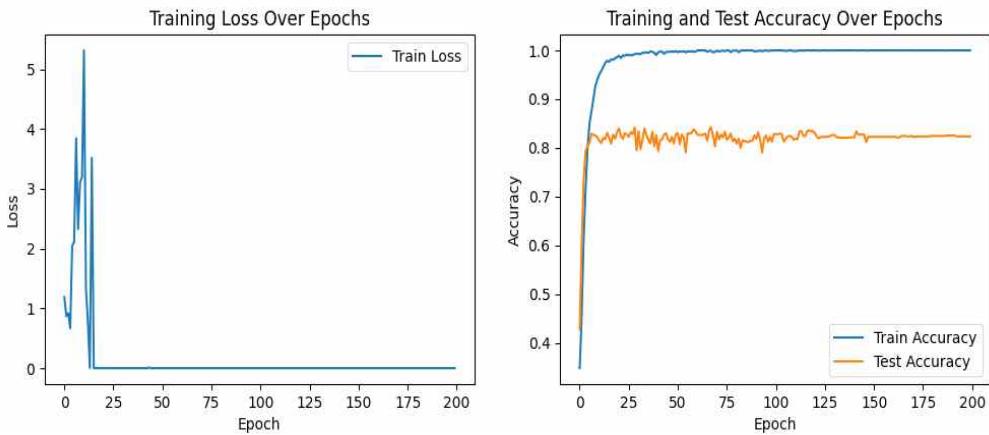


그림 21. KoBERT 기반 감정분석 모듈에 대한 정확도 그래프

본 논문은 기존 챗봇 시스템(데이터 전체를 학습), 문장 생성에 많이 사용되는 KoGPT 모델과 제안한 시스템(선택적 Llama 2 챗봇 모듈)의 챗봇 시스템의 정확도를 측정하고 비교한다. 챗봇 시스템의 정확도는 실제 답변과 얼마나 유사하게 답변을 생성했는가에 대해 계산한다[28].

표 9는 정답 답변과 제안한 챗봇 시스템이 도출한 답변을 비교하였다. 그 결과, 1번의 정답 답변에는 ['놀라다'], 제안한 시스템의 챗봇 답변에는 ['심장이 뛰는 줄 알고 있었다.'], 2번 정답 답변에서는 ['사과하셨다'], 제안한 시스템의 챗봇 답변에도 ['사과하셨다'] 등 비슷한 감정적 답변을 한 것을 확인할 수 있다.

표 9. 제안한 시스템의 챗봇 답변 결과

	사람문장 1	정답 답변	제안한 시스템의 챗봇 답변
1	내 친구가 나 대신 나섰다가 폭행을 당했다는 소식을 듣고 심장이 뛰는 줄 알았어!	친구가 폭행을 당했다는 소식에 많이 놀라셨군요.	친구가 대신 나서서 폭행을 당했다는 소식을 듣고 심장이 뛰는 줄 알고 있었군요.
2	오늘 선생님이 내가 괴롭힘 당하고 있는 걸 몰랐던 것에 대해 사과하셨어.	선생님께서 괴롭힘당하던 걸 모르셨다고 사과하셨군요.	선생님이 괴롭힘당하고 있는 걸 몰랐던 것에 대해 사과하셨군요.
3	내 친구가 어떤 애한테 맞고 와서 기분이 상당히 암울하네.	친한 친구가 맞았다니 기분이 편치 않겠어요.	친구가 어떤 애한테 맞고 와서 기분이 상당히 암울하군요
4	오늘 친구랑 속 깊은 얘기를 나눴어.	친구와 마음속 깊은 얘기를 나눌 수 있어 좋으셨겠어요.	친구랑 속 깊은 얘기를 나눔으로 오늘 좋은 일이 있으신가요
5	기분이 나빠도 그냥 넘어가는 내가 바보 같아서 슬퍼.	그냥 넘어간 사실이 바보같이 느껴져서 슬프셨군요.	기분이 나빠 슬프셨군요

따라서 표 9는 제안 모델에 의해 생성된 챗봇 답변이 정답과 유사함을 보여준다. 본 논문에서는 제안한 모델에 의해 생성된 챗봇 답변과 정답 간의 유사성을 수치적으로 검증하였다. 또한, 본 논문에서는 제안하는 시스템 챗봇의 성능을 기준 챗봇 시스템[KoGPT, Llama2]과 비교하여 검증한다. 본 논문에서는 유사성을 측정하기 위해 코사인 유사성과 BLEU 정확도 공식을 사용한다[28]. 코사인 유사도는 1에 가까울수록 유사도가 높다고 평가한다[28]. 본 논문에서 사용한 코사인 유사도 공식은 수식 6과 같다. 수식 6에서 A와 B는 벡터화된 단어의 값이다.

$$\text{CosineSimilarity} = \frac{A^*B}{\|A\|\|B\|}$$

수식 6. 코사인 유사도 수식

본 논문은 문장에 사용된 단어들의 간의 유사도 합을 통해 정확도를 도출하였고 문장의 단어들을 임베딩 모델 중 하나인 Countervector 임베딩을 통해 벡터화하였다. 표 10은 각 모델의 코사인 유사도를 구한 결괏값이다.

표 10. 챗봇 시스템의 코사인 유사도 값

챗봇 시스템명	코사인 유사도 값
KoGPT(Based_System)	0.73
Llama 2(Based_System)	0.81
선택적 Llama 2 챗봇 모듈(Proposed_System)	0.86

그림 22는 제안된 챗봇 모델과 기존 챗봇 모델[KoGPT, Llama2]의 코사인 유사성 결과를 그래프로 나타낸 것이다. 그림 22는 왼쪽부터 KoGPT, Llama2, 제안 시스템(선택적 Llama2 챗봇 모듈)의 코사인 유사성 결과를 나타낸다. 실험 결과, 제안한 시스템이 기존 챗봇 시스템들보다 코사인 유사도 0.86으로 가장 높은 결과를 도출하였다. 또한, 제안된 챗봇 시스템이 기존 챗봇 시스템들과 비교해 더 높은 성능의 코사인 유사성 그래프를 생성한 것을 확인하였다.

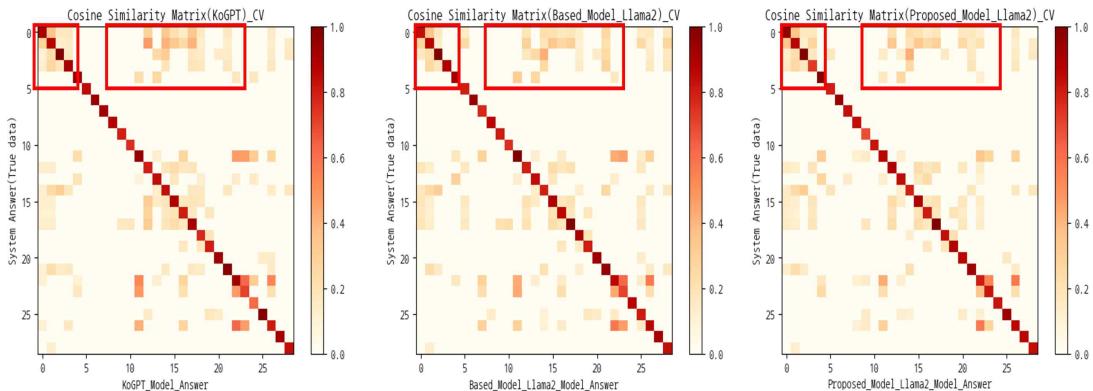


그림 22. 코사인 유사도 결과 그래프(왼쪽부터: KoGPT, Llama2, Proposed System)

본 논문은 챗봇 정확도 측정에 많이 사용되는 BLEU 값을 이용하여 정확도를 비교하였다. BLEU는 정답 문장의 단어가 챗봇 시스템을 통해 도출된 예측 문장의 단어에 얼마나 포함되는가처럼 n-gram 방식을 이용하여 측정하는 방식이다[30]. 사용한 BLEU의 수식은 수식7과 같다. Pn은 gram의 보정된 정밀도, N은 n-gram에서 n의 최대 숫자, Wn은 가중치, BP는 문장 길이에 대한 폐널티다[30]. 표 11은 챗봇 시스템 간의 BLEU 결과값이다. 표 11은 BLEU 값을 백분율로 변환한 값이다.

$$BLEU = BP^* \exp \left(\sum_{n=1}^N w_n \log p_n \right)$$

수식 7. 사용한 BLEU 수식

표 11. 챗봇 시스템 간의 BLEU 결괏값

챗봇 시스템명	BLEU 값
KoGPT(Based_System)	0.887
Llama 2(Based_System)	0.899
선택적 Llama 2 챗봇 모듈(Proposed_System)	0.906

그림 23은 왼쪽부터 KoGPT, Llama2, 제안 시스템(선택적 Llama2 챗봇 모듈)에 대한 30개 테스트 데이터의 BLEU 결과 그래프이다.

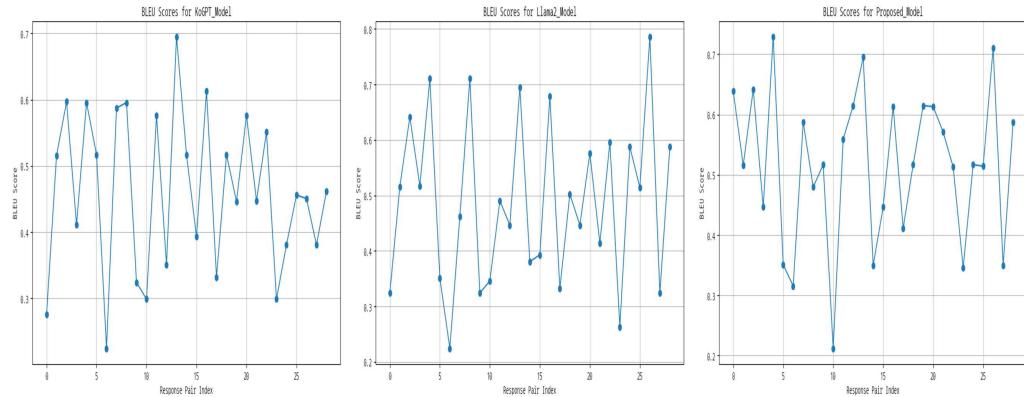


그림 23. BLEU 결과 그래프(왼쪽부터: KoGPT, Llama2, Proposed System)

실험 결과, 기존 방식의 챗봇에 비해 제안한 시스템의 BLEU 값이 0.906으로 높은 정확도를 도출하는 것을 확인하였다.

V. 결론

본 논문에서는 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 모델 설계를 제안하였다. 제안된 모델은 상황에 따른 감정분석을 위한 BER T 기반 딥러닝 모듈(DL_Emotioner), 문장 자체의 직관적인 감정분석을 위한 양상을 머신러닝 기반 머신러닝 모듈(ML_Emotioner), DL_Emotioner와 ML_Emotioner를 융합하는 Mixture_Emotioner 모듈을 제안하였다. 제안하는 시스템은 단일 분류 모델을 이용하여 감정분석하는 감정 시스템에 비해 높은 성능을 도출하였다.

본 논문에서는 제안한 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 모델의 응용으로 3가지 시스템을 구현하였다. 첫 번째로 단어의 감정적 요소를 포함하는 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 시스템을 구현하였다. 제안한 시스템은 단어의 감성적 요소를 고려한 시스템을 제안하여 상세한 감성을 분석하였다. 두 번째로 반복적인 문장 혹은 단일 문장을 말하는 자폐 아동들의 감정분석을 위해 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국 자폐 아동들의 감정분석 시스템을 구현하였다. 제안한 시스템은 제안한 딥러닝과 양상을 머신러닝을 융합한 모델이 다른 감정분석 모델보다 감정분석 정확도가 가장 높았다. 세 번째로 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 한국인 감정분석 시스템을 이용한 선택적 Llama2 모델 감정분석 챗봇 시스템을 설계하였다. 제안한 시스템은 대규모 언어 모델(LLM)과 양상을 머신러닝 모델을 융합한 모델을 이용하여 감정분석 챗봇의 성능을 향상시켰다.

현재 공개된 대규모 언어 모델 중 Llama 2가 성능이 가장 좋음에도 불구하고 본 논문에서는 KoBERT와 Llama 2 모델 비교를 하였을 때 KoBERT가 더 좋은 성능을 도출하였다. 그 이유로는 Llama 2가 현재 영어 데이터로 더 많이 사전학습 되었기 때문에 한국어의 특성을 잘 반영하지 못한다. 따라서 추후에는 Llama 2를 한국어 특성을 포함하도록 사전학습을 시키고 사전학습된 한국어 Llama 2 모델을 사용하여 감정분석 시스템을 설계하는 연구가 필요하다. 또한, 현재 Llama 2 모델은 다양한 크기로 제공되고 있다. 하지만 적은 메모리를 가진 컴퓨터로는 Llama 2 모델 재학습의 한계가 존재한다. 따라서 Llama 2를 재학습할 시 적은 메모리로도 학습할 수 있도록 최적화 할 수 있는 방향의 연구가 필요하다. 또한, 추후에는 딥러닝과 머신러닝의 Hyperparameter 최적화 및 상황에 알맞은 데이터 수집 후 학습을 통해 개인의 상황에 따른 감정분석 시스템의 정확도를 개선해야 한다.

참고 문헌

- [1] Noh Song Hyeon, Han Chae Yeon, & Park Joo Seong (2022-06-22). A Study on Development and Prospects of Untact Service by Digital Transformation in the Post Covid-19 Era. Proceedings of Symposium of the Korean Institute of Communications and Information Sciences, 제주.
- [2] OpenAI. (2023). ChatGPT (May 24 version) [Large language model]. <https://chat.openai.com>.
- [3] Hyundeuk Cheon (2017). Artificial intelligence and artificial emotions – Is an emotion robot realizable? -. Korean Journal of Philosophy, 131, 217–243, 10.18694/KJP.2017.05.131.217.
- [4] 김민영 (2022). EfficientNet Architecture-Based Systems and Algorithms for Predicting Emotions in Humans [Master's Thesis, 계명대학교]. <http://www.riss.kr/link?id=T16192067>.
- [5] Dawel, Amy, et al. "Perceived emotion genuineness: normative ratings for popular facial expression stimuli and the development of perceived-as-genuine and perceived-as-fake sets." Behavior research methods 49 (2017): 1539–1562.
- [6] Devlin, Jacob, et al. "Bert: Pre-training of deep bidirectional transformers for language understanding." arXiv preprint arXiv:1810.04805 (2018).
- [7] Santos, Igor, Nadia Nedjah, and Luiza de Macedo Mourelle. "Sentiment analysis using convolutional neural network with fastText embeddings." 2017 IEEE Latin American conference on computational intelligence (LA-CCI). IEEE, 2017.
- [8] Gao, Xianwei, et al. "An adaptive ensemble machine learning model for intrusion detection." Ieee Access 7 (2019): 82512–82521.
- [9] Wang, Ruibo, and Jihong Li. "Bayes test of precision, recall, and F1 measure for comparison of two natural language processing models." Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019.
- [10] JeongMi Lee. "Study on Spontaneous Communicative Behavior in Children with Autism." Emotional and Behavioral Disorder Research 23, no.4 (2007): 345–359.
- [11] SangMin Park, JaeYoon LeeYu Ri Sung, JaeEun Kim. (2022). SBERT-IQ: A Sentence-BERT-based embedding model considering keyword information cont

- ent. Proceedings of the Korean Information Science Society, (), 1058–1060.
- [12] Nils Reimers, Iryna Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," In Proceedings of Empirical Methods in Natural Language Processing, pp. 3980–3990, 2019.
- [13] HuiWon Song, JuHyun Lee, SungHae Jun, SangSung Park. (2022). A Study on Inferable Patent Evaluation Model using Ensemble Method. Journal of Korean Institute of Intelligent Systems, 32(5), 379–385.
- [14] Seunguook Lim, & Jihie Kim (2021). RNN model for Emotion Recognition in Dialogue by incorporating the Attention on the Other's State. Journal of KIIS E, 48(7), 802–808, 10.5626/JOK.2021.48.7.802
- [15] Lee, Sangah, et al. "Kr-bert: A small-scale korean-specific language model." arXiv preprint arXiv:2008.03979 (2020).
- [16] Touvron, Hugo, et al. "Llama 2: Open foundation and fine-tuned chat models." arXiv preprint arXiv:2307.09288 (2023).
- [17] 임충훈. "가맹점 거래의 효율적 분류를 위한 머신러닝 기반의 스태킹 양상을 기법." 국내석사학위논문 한양대학교 공학대학원, 2024. 서울.
- [18] AI_Hub, <https://www.aihub.or.kr>
- [19] Min, Moohong, Jemin J. Lee, and Kyungho Lee. "Detecting illegal online gambling (IOG) services in the mobile environment." Security and Communication Networks 2022 (2022).
- [20] X. Dong, K. Yu and Z. Cui, "Readmission prediction of diabetic patients based on AdaBoost-RandomForest mixed model," 2022 3rd International Conference on Big Data, Artificial Intelligence and Internet of Things Engineering (ICBAIE), Xi'an, China, 2022, pp. 130–134, doi: 10.1109/ICBAIE56435.2022.9985819.
- [21] Datta, Leonid. "A survey on activation functions and their relation with xavier and he normal initialization." arXiv preprint arXiv:2004.06632 (2020).
- [22] HuiWon Song, JuHyun Lee, SungHae Jun, SangSung Park. (2022). A Study on Inferable Patent Evaluation Model using Ensemble Method. Journal of Korean Institute of Intelligent Systems, 32(5), 379–385.
- [23] SungEun Gil. (2020). Research on action-based authentication by cosine similarity measure Proceedings of the Annual Meeting of the Korean Information Processing Society, 27(1), 165–168.

- [24] Junghyun Cho, Hyunki Jung, Chanyoung Park, and Yuseop Kim. "An Autonomous Assessment of a Short Essay Answer by Using the BLEU" Korean HCI Conference 2009.2 (2009): 606–610.
- [25] Eungju Kwon, Jongwoo Kim, Nojeong Heo, and Sanggil Kang. "Personalized Recommendation System using Level of Cosine Similarity of Emotion Word from Social Network" Information Technology Architecture Research 9.3 (2012): 333–344.
- [26] Dongho Lee, Minseo Lee, Jaeseo Lee, Heejo Park, Hyunsung Jun, Seehwan Yoo.(2021).Real-time adaptive model training technique using Pearson correlation coefficient. Proceedings of the Korean Information Science Society Conference,1536–1538.
- [27] Sanjeev Kumar, Mahesh Chandra). "Detection of Microcalcification Using the WaveletBased Adaptive Sigmoid Function and Neural Network." Journal of informationprocessing systems 13.4 (2017): 703–715.
- [28] Xia, Peipei, Li Zhang, and Fanzhang Li. "Learning similarity with cosine similarity ensemble." Information sciences 307 (2015): 39–52.
- [29] Xu, Canwen, et al. "Beyond preserved accuracy: Evaluating loyalty and robustness of BERT compression." arXiv preprint arXiv:2109.03228 (2021).
- [30] Papineni, Kishore, et al. "Bleu: a method for automatic evaluation of machine translation." Proceedings of the 40th annual meeting of the Association for Computational Linguistics. 2002.
- [31] Chung, D. "A Case Study of Visualizing Emotions with Social Media Emotion Analysis - Focused on Media." (2022).

Design of Korean Emotion Analysis Model Combining Large Language Model (LLM) and Ensemble Machine Learning Model

Hyeonji Kim

Department of Information and Communication Engineering
Graduate School, Daegu University,
Gyeongbuk, S.Korea

Supervised by Prof. Yoosoo Oh

(Abstract)

Recently, with the development of the artificial intelligence market, there has been a growing number of cases where artificial intelligence has replaced jobs. However, some jobs cannot be replaced by artificial intelligence. Most jobs that cannot be replaced by artificial intelligence, such as childcare teachers and psychological counselors, are unlikely to be replaced by occupations that require emotional interaction with humans. Emotions are defined as thoughts or feelings that are manifested in external situations. In this way, emotions highly influenced by the situation are difficult to understand by artificial intelligence that only learns through algorithms train methods.

Human emotions can be expressed through language, voice, and facial expressions. Language is emotional because it constructs and expresses meaningful words depending on the situation. However, voice and facial expressions can mask or control how emotions are expressed through a person's will. Also, unlike English, Korean has compound words and homonyms with different meanings depending on the context. Therefore, in this paper, we identify contextual linguistic sentiment through deep learning and sentence sentiment through machine learning. Then, we combine the results of the two models to build a large-scale language

model (LLM) and ensemble machine learning capable of sentiment analysis. We propose designing a Korean emotion analysis model that combines learning models.

The proposed Korean emotion analysis model includes an emotion analysis module using deep learning (DL_Emotioner), an emotion analysis module using an ensemble machine learning algorithm (ML_Module) and a Mixture_Emotioner module that combines DL_Emotioner and ML_Emotioner. DL_Emotioner is implemented through the BERT algorithm and achieves high performance in context understanding. ML_Emotioner is implemented using an ensemble machine learning algorithm that outperforms single classification machine learning models.

In this paper, the final emotion is obtained by combining a machine learning algorithm capable of situational emotion analysis using deep learning through Mixture_Emotioner as well as sentence emotion capable of accurate emotion analysis considering the characteristics of the Korean language. In this paper, detailed sentiment analysis is possible by combining situational sentiment analysis and sentiment analysis of sentences or words. In this paper, the proposed system's performance is verified through the implementation of various application systems. This paper implemented three sentiment analysis systems by applying the Korean sentiment analysis model, which combines a large-scale language model with an ensemble machine-learning model. First, this paper presents a Korean emotion analysis system that combines a Large-scale Language Model (LLM) containing emotional elements of words and an Ensemble machine-learning model. Second, we present a sentiment analysis system for autistic Korean children that combines a Large-scale Language Model (LLM) and an Ensemble machine-learning model. Finally, we designed a selective Llama2 model sentiment analysis chatbot system using the Korean sentiment analysis system that combines a Large-scale Language Model (LLM) and an Ensemble machine learning model.